

Universidad Nacional Autonoma de México
Facultad de Ingeniería
Cuaderno

Celaya González David Alejandro
Grupo: 02
Estadística
22/Enero/2021

ESTADÍSTICA:

EVALUACIÓN

EXAMENES	60%	Asistencia 80%.
TAREAS	30%	3 EXAMENES DURANTE EL SEMESTRE
PARTICIPACIÓN	10%	TAREAS SEMANALES
CUADERNO	5%	TAREAS A MANO

DISTRIBUCIONES: FISHER, NORMAL, T-STUDENT, JI - CUADRADA.
 PARÁMETROS: MEDIA, VARIANZA, PROPORCIÓN

ESTADÍSTICA DESCRIPTIVA.

LA FORMA CIENTÍFICA DE VALIDAR LA INVESTIGACIÓN ES A TRAVÉS DE LA PROBABILIDAD Y LA ESTADÍSTICA.

INVESTIGAR VIENE DEL VOCABLO INVESTIGARE → HACER DILIGENCIAS PARA DESCUBRIR ALGO.

INVESTIGACIÓN BÁSICA: TIENE POR OBJETO MISMO LA INVESTIGACIÓN, ES DECIR, SÓLO PERSIGUE EL CONOCIMIENTO DE LAS COSAS.

MÉTODO CIENTÍFICO: LOGRAR UN PROPOSITO, DEBEN SEGUIR UNA METODOLOGÍA.

ESTADÍSTICA: SIGNIFICA CIENCIA DEL ESTADO.

LA ESTADÍSTICA NO SOLO PROPORCIONA INFORMACIÓN O DATOS; SINO QUE LOS AGRUPA, ANALIZA, INTERPRETA Y PERMITE GENERAR INFERNCIAS O CONCLUSIONES DE UNA POBLACIÓN A PARTIR DE DATOS DE UNA MUESTRA.

ESTADÍSTICA COMO DEFINICIÓN: RAMA DE LAS MATEMÁTICAS QUE SE ENCARGA DE LA SELECCIÓN DE DATOS, SU ORGANIZACIÓN, PRESENTACIÓN Y REALIZACIÓN DE LAS CONCLUSIONES QUE SE PUEDEN OBTENER DE DICHOS DATOS.

DE CLASIFICA.

- UNIVARIABLE Y MULTIVARIABLE (NÚMERO DE VARIABLES)
- DESCRITIVA - INFERNICIAL (APLICACIÓN)
- PARÁMETRICA Y NO PARÁMETRICA (BASADA EN LA INFORMACIÓN QUE POSEE)

POBLACIÓN: CONJUNTO DE INDIVIDOS QUE SE ESTUDIAN CON BASE EN UNA CARACTÉRISTICA

MUESTRA: ES UN SUBCONJUNTO DE LA POBLACIÓN.

ETAPAS DE LA INFORMACIÓN QUE SE DEBE REALIZAR EN LA ESTADÍSTICA:

- 01 - REUNIR
- 02 - ORGANIZAR
- 03 - ANALIZAR

PARA REUNIR LA INFORMACIÓN SE REQUIERE DEFINIR AL CARÁCTER QUE VAMOS A ESTUDIAR.

ORDENAR → GERARQUIZAR. ORGANIZAR → CUALITATIVOS
 (NO PUEDO CAMBIAR EL ORDEN)

CELAYA GONZÁLEZ DAVID A.

28-SEP-29

ESCALAS DE MEDICIÓN

- CUANDO LA VARIABLE SOLO SE LE PUEDE CLASIFICAR PUEDE SER UN ATRIBUTO.

 - NOMINAL → NO ORDENADO
 - ORDINAL → SI SE PUEDE HACER COMPARACION DE UN ATRIBUTO } CUAN.
 - INTERVALOS → EL CERO NO ES ABSOLUTO (TEMPERATURA)
 - RAZÓN O PROPORCIÓN → CERO ABSOLUTO. } CUAN.

MUESTREO: SE TOMA UNA MUESTRA PARA ESTUDIAR LA POBLACION.

TECNICAS DE MUESTREO.

ALEATORIO SIMPLE: ES CUANDO LOS ELEMENTOS DE UNA POBLACIÓN TIENEN LA MISMA PROBABILIDAD DE SER SELECCIONADOS. SE REQUIEREN 4 COSAS.

- NUMERAR A CADA INDIVIDUO DE LA POBLACIÓN
 - CUANTIFICAR EL TAMAÑO DE LA MUESTRA ($n = \text{MUESTRA}$) ($N = \text{POBLACIÓN}$)
 - ELEGIR CON UN GENERADOR DE NÚMEROS ALÉATORIOS.
 - LA MUESTRA SERÁN LAS ' n ' NÚMEROS QUE SE SELECCIONARON EN EL PASO ANTERIOR.

OJO: EN LA PRÁCTICA ES DIFÍCIL OCUPAR ESTA TÉCNICA.

ESTRATIFICADO: CUANDO A LA POBLACIÓN LA DIVIDES EN ESTRATOS Y SE REQUIERE QUE EN LA MUESTRA APARESCA UNO DE CADA ESTRATO

CONGLOMERADOS: SIMILAR AL ESTRATIFICADO PERO PARA POBLACIONES MUY GRANDES. NO SE ESTUDIAN TODOS LOS ESTRATOS

SISTEMATICO: POR ALGÚN MÉTODO SISTEMÁTICO SE PIDE GENERAR UNA MUESTRA (TIEMPO O INDIVIDOS)

ESTADÍSTICA DESCRIPTIVA

ES LA PARTE DE LA ESTADÍSTICA QUE TIENE COMO PROPOSITO ORGANIZAR Y PRESENTAR LOS DATOS DE UNA POBLACIÓN O DE UNA MUESTRA PARA SU ANÁLISIS E INTERPRETACIÓN.

TRES TECNICAS.

- DISTRIBUCIÓN DE FRECUENCIAS: FORMA EN QUE SE AGRUPAN LOS DATOS (CUALITATIVOS Y CUANTITATIVOS)
 - GRÁFICAS: VISUALIZAR LA FORMA EN QUE SE AGRUPAN LOS DATOS (CUALITATIVOS)
 - MEDIDAS NÚMERICAS: RESUMEN DE LOS DATOS EN FORMA CUANTITATIVA. (CUANTITATIVOS)

EXISTE UNA GRAN VARIEDAD DE TABLAS DE DISTRIBUCIÓN DE FRECUENCIAS; SIN EMBARGO, AQUÍ SE ESTUDIARÁ UNA TABLA TEÓRICA COMPLETA. PARA RESUMIR LOS DATOS, SE UTILIZAN INTERVALOS, CLASES O CATEGORIAS Y POSTERIORMENTE SE INDICAN LA FRECUENCIA DE C/U DE ELLOS.

LAS COLUMNAS QUE FORMAN UNA TABLA COMPLETA SON:

CLASES

- LÍMITES DE CLASE (L_i)
- FRONTERAS DE CLASE: LAS FRONTERAS O LÍMITES VERDADEROS DE UNA CLASE, SON LOS PUNTOS MÉDICOS ENTRE LOS LÍMITES DE INTERVALOS CONSECUTIVOS: (L_{ri})

LÍMITES DE CLASE
1 - 3
4 - 6
7 - 9

FRONTERAS DE CLASE
0.5 (1 - 0.5) - 3.5 (3 + 0.5)
3.5 (4 - 0.5) - 6.5 (6 + 0.5)
6.5 (7 - 0.5) - 9.5 (9 + 0.5)

- MARCAS DE CLASE (x_i): ES EL PUNTO MEDIO DE UNA CLASE. SE CONSIDERA COMO EL VALOR REPRESENTATIVO DE UN INTERVALO. LAS MARCAS DE CLASE SE OBTIENEN PROMEDIANDO LOS LÍMITES DE UN INTERVALO, O BIEN, LAS FRONTERAS.

MARCA DE CLASE
2
5
8

FRECUENCIA:

- FRECUENCIA: ES EL NÚMERO DE ELEMENTOS EN LA MUESTRA O EN LA POBLACIÓN QUE PERTENECE A LA CLASE EN CUESTIÓN.
SI LOS DATOS DE UNA MUESTRA SON: 1, 9, 5, 8, 4, 1, 2, 7, 6, 3, 3, 2, 7, 9
¿ENTONCES COMO QUEDARÍAN AGRUPADOS EN CLASES? (f_i)

FRECUENCIA
6
3
5

CECAYA

- FRECUENCIA ACUMULADA: ES EL NÚMERO DE DATOS EN LA NUESTRA O POBLACIÓN, QUE SON MENORES O IGUALES QUE EL LÍMITE SUPERIOR DEL INTERVALO EN CUESTIÓN. SE OBTIENE SUMANDO LA FRECUENCIA DEL INTERVALO ACTUAL Y DE LOS ANTERIORES INTERVALOS. (F_i)

FRECUENCIA ACUMULADA	
6	
6 + 3 = 9	
6 + 3 + 5 = 14	

TIENE QUE SER IGUAL AL TOTAL EN FRECUENCIAS.

- FRECUENCIA RELATIVA: ES LA PROPORCIÓN DE DATOS QUE PERTENECEN A LA CLASE EN CUESTIÓN. ES EL NÚMERO O COCIENTE DE LA FRECUENCIA ENTRE EL NÚMERO TOTAL DE DATOS (f_i^*)

$$f_i^* = \frac{f_i}{n}$$

PARA LA TABLA DEL EJEMPLO, SI EL TOTAL DE DATOS ES $n = 100$,

ENTONCES:

FRECUENCIA RELATIVA	
6/100 = 0.06	
3/100 = 0.03	
5/100 = 0.05	

- FRECUENCIA ACUMULADA RELATIVA:

FRECUENCIA ACUMULADA RELATIVA	
0	
0.06	
0.11	

02/10/2020

GRÁFICAS:

CUANDO SE DESEA UN MAYOR IMPACTO DE LA FORMA EN LA QUE SE DISTRIBUYEN LOS DATOS, ESTOS SE PRESTAN EN UNA O VARIAS GRÁFICAS.

SON MUCHAS LAS GRÁFICAS QUE SE PUEDEN UTILIZAR EN LA ESTADÍSTICA DESCRIPTIVA, DESTACANDO:


- EL HISTOGRAMA
- EL POLÍGONO
- LA OSIVA
- SECTORES CIRCULARES
- LA PÉTALOS Y HOJAS
- EL DIAGRAMA DE CASA.

HISTOGRAMA: CUANTI - CUALI

EL HISTOGRAMA ES UNA GRÁFICA DE BARRAS RECTANGULARES CUYAS BASES ESTÁN CENTRADAS EN LA MARCA DE CLASE DEL INTERVALO, Y SUS ÁREAS PROPORCIONALES A LA FRECUENCIA DEL INTERVALO.


- GRÁFICA DE BARRAS CONVENCIONAL ES PARA DATOS CUALITATIVOS.

- HISTOGRAMA ES PARA DATOS CUANTITATIVOS.



POLÍGONO DE FRECUENCIA CUANTI - CUALI


EL POLÍGONO DE FRECUENCIAS ES UNA GRÁFICA POLIGONAL O DE LÍNEAS RECTAS QUE INDICA PARA CADA MARCA DE CLASE LA FRECUENCIA. SE OBTIENE UNIENDO LOS PUNTOS MÉDIO DE LAS PARTES SUPERIORES DE LAS BARRAS DEL HISTOGRAMA.



CECAYA

OJIVA: (NO SE OCUPA PARA DATOS CUALITATIVOS)

LA OJIVA ES TAMBÍEN UNA GRÁFICA POLIGONAL, DEDO SE DIBUJA UTILIZANDO (A) LAS FRONTERAS CONTRA LAS FRECUENCIAS ACUMULADAS (O ACUMULADAS RELATIVAS). LA OJIVA INDICA, PARA CADA FRONTERA, LOS ELEMENTOS (O PROPORCIÓN DE ELEMENTOS), QUE SON MENORES O IGUALES QUE DICTA FRONTERA.



SECTORES CIRCULARES (PPY)

LA GRÁFICA DE SECTORES CIRCULARES NOS INDICA POR MEDIO DE LA FRACCIÓN DE UN CÍRCULO LA FRECUENCIA RELATIVA DE LA CLASE EN CUESTIÓN.




DIAGRAMA DE TALLO Y HOJAS: ES UNA REPRESENTACIÓN SEMI-GRÁFICA, UTILIZADA PARA DATOS CUANTITATIVOS, UTILIZADA AMPLIAMENTE EN LA DÉCADA DE LOS ochenta, CUANDO LAS COMPUTADORAS NO REALIZABAN GRÁFICAS MÁS ESTADÍSTICAS COMO LOS HISTOGRAFAS. CONSISTE EN SEPARAR LOS NÚMEROS EN DOS PARTES, POR EJEMPLO DECENAS 200 Y UNIDADES.

DATOS: 20, 25, 40, 36, 72, 25, 25

D	U				
2	0 555		5	2 2	(4) 1
3	6		2	2 2	(5) 1
4	0		8	2 8	(1) 1
5					
6					
7	2				
8					

DIAGRAMA DE CAJA: ES UNA FORMA DE PRESENTACIÓN ESTADÍSTICA DESTINADA FUNDAMENTALMENTE A RESALTAR ASPECTOS DE LA DISTRIBUCIÓN DE LAS OBSERVACIONES EN UNA O MÁS SERIES DE DATOS CUANTITATIVOS. REMPLAZA, EN CONSECUENCIA, AL HISTOGRAMA Y A LA CURVA DE DISTRIBUCIÓN DE FRECUENCIAS SOBRE LOS QUE TIENE VENTAJAS A LA INFORMACIÓN QUE BRINDA Y A LA APPRECIACIÓN GLOBAL QUE SURGE DE LA LECTURA.

NOTA: PARA REALIZAR EL DIAGRAMA DE CAJA PRIMERO DEBEMOS CONOCER LAS MEDIDAS NÚMERICAS.

(1) $\text{Mínimo} = 10 \quad \text{Máximo} = 30 \quad \text{Media} = 23 \quad \text{Moda} = 20 \quad \text{Mediana} = 20$

$\text{Desviación Estándar} = \sqrt{\frac{\sum (x - \bar{x})^2}{n}} = \sqrt{\frac{(10-20)^2 + (10-20)^2 + (10-20)^2 + (10-20)^2 + (10-20)^2 + (10-20)^2 + (10-20)^2 + (10-20)^2 + (10-20)^2 + (10-20)^2}{10}} = \sqrt{\frac{100+100+100+100+100+100+100+100+100+100}{10}} = \sqrt{100} = 10$

$\text{Coeficiente de Asimetría} = \frac{n}{\sum (x - \bar{x})^3} = \frac{10}{(10-20)^3 + (10-20)^3 + (10-20)^3 + (10-20)^3 + (10-20)^3 + (10-20)^3 + (10-20)^3 + (10-20)^3 + (10-20)^3 + (10-20)^3} = \frac{10}{-1000} = -0.1$

$\text{Coeficiente de Simetría} = \frac{n}{\sum (x - \bar{x})^2} = \frac{10}{(10-20)^2 + (10-20)^2 + (10-20)^2 + (10-20)^2 + (10-20)^2 + (10-20)^2 + (10-20)^2 + (10-20)^2 + (10-20)^2 + (10-20)^2} = \frac{10}{100} = 1$

CECPYR

DISTRIBUCIÓN DE FRECUENCIAS POR INTERVALOS: EXISTEN OTRAS TABLAS DE DISTRIBUCIÓN DE FRECUENCIAS, BASADAS EN INTERVALOS, EN DONDE SE UTILIZA LA NOTACIÓN DEL CÁLCULO PARA LOS INTERVALOS ABIERTOS Y CERRADOS POR EJEMPLO:

INTERVALO	MARCA DE CLASE x_i	FRECUENCIA f_i
[1, 4)	2.5	2
[4, 7)	5.5	5
[7, 10)	8.5	8
⋮	⋮	⋮

VALORES QUE AYUDAN A CONSTRUIR UNA TABLA DE DISTRIBUCIÓN DE FRECUENCIAS: LONGITUD DE CLASE. ES LA DIFERENCIA ENTRE LA FRONTERA SUPERIOR Y LA INFERIOR DE UNA MISMA CLASE. SE DENOTA POR C .

LA LONGITUD DE CLASE DE LA TABLA ANTERIOR ES: 3

RECOMENDACIONES PARA LA CONSTRUCCIÓN DE UNA TABLA DE DISTRIBUCIÓN DE FRECUENCIAS:

- EL NÚMERO DE CLASES ESTARÁ ENTRE 5 Y 20, INCLUSIVE. LA PRIMERA APROXIMACIÓN DEL NÚMERO DE CLASES SE OBTENDRÁ CON \sqrt{n}
- TODAS LAS CLASES SERÁN DE LA MISMA LONGITUD (C)
- LA LONGITUD DE CLASE SE APROXIMA MEDIANTE $C = \frac{\text{RANGO}}{\# \text{ DE CLASES}}$, DONDE EL RANGO ES: $y_{\text{MÁXIMO}} - y_{\text{MÍNIMO}}$
- POSTERIORMENTE SE AJUSTA DE MANERA CONVENIENTE, DE FORMA QUE EL PRIMER LÍMITE INFERIOR SEA LIGERAMENTE MENOR O IGUAL QUE EL MENOR VALOR, Y EL ÚLTIMO LÍMITE SUPERIOR SEA LIGERAMENTE MAYOR O IGUAL QUE EL MAYOR DATO.
- TRATARÁ DE EVITARSE QUE HAYA CLASES CON FRECUENCIA CERO.


EJEMPLO.

LOS SIGUIENTES VALORES REPRESENTAN EL TIEMPO DIARIO DE TRASPORTE DE UNA MUESTRA DE 50 TRABAJADORES DE CIERTO HOSPITAL EN LA CDMX

69	56	73	66	64	44	36	69	76	53
79	72	82	77	71	48	49	49	60	67
73	70	64	56	31	62	58	55	51	45
30	40	80	49	59	60	76	67	30	72
45	43	77	49	46	42	63	91	64	79

ORDENAR LOS DATOS

DIAGRAMA DE TALLO Y HOJAS



Suma 50 ✓

ORDENADOS

30	30	31	36	40	41	42	43	44	45
45	46	48	49	49	49	49	49	51	53
56	56	56	59	60	60	62	63	64	64
64	66	67	67	69	69	70	71	72	77
73	73	76	76	77	77	79	79	80	82

Norma

CECPY12



LÍMITE DE CLASE	FRONTERA DE CLASE	MARCAS DE CLASE	FRECUENCIA	F. ACUMULADA	F. RELATIVA
29 - 36	28,5 - 36,5	32,5	4	4	0,08
37 - 44	36,5 - 44,5	40,5	5	9	0,16
45 - 52	44,5 - 52,5	48,5	9	18	0,18
53 - 60	52,5 - 60,5	56,5	8	26	0,16
61 - 68	60,5 - 68,5	64,5	8	34	0,16
69 - 76	68,5 - 76,5	72,5	10	44	0,2
77 - 84	76,5 - 84,5	80,5	6	50	0,12
F. A. RELATIVA			TOTAL = 50		TOTAL = 1
0,08					
0,18					
0,36					
0,52					
0,68					
0,88					
1					

○ EN EL NÚMERO DE CLASES VALOR HACIA ABAJO $\sqrt{50} = 7,07 \Rightarrow 7$ CLASES.

$$\text{○ RANGO} = 82 - 30 \Rightarrow c = \frac{52}{7} = 7,42 \Rightarrow 8$$

LA LONGITUD DE CLASE * # DE CLASES > RANGO.

QJO: LA LONGITUD DE CLASE SERÁ LA DISTANCIA ENTRE LAS FRONTERAS NO ENTRE LOS LÍMITES



$$\bar{x} = \frac{\sum f_i m_i}{\sum f_i}$$

$$\bar{x} = \frac{\sum f_i m_i}{\sum f_i}$$

$$\bar{x} = \frac{\sum f_i m_i}{\sum f_i}$$

CECAYA

MEDIDAS NÚMERICAS: ~~Agrupados~~

NOTA: CON LA TABLA DE DISTRIBUCIÓN DE FRECUENCIAS Y CON LAS GRÁFICAS, SE DESCRIBE EL COMPORTAMIENTO DE UN CONJUNTO DE DATOS; SIN EMBARGO, PARA NO CAER EN SUBLIMINIDADES, O ERRORES POR LA ESCALA, SE UTILIZAN TAMBÉN LAS MEDIDAS NÚMÉRICAS.

LAS MEDIDAS NÚMÉRICAS, POR EL TIPO DE INFORMACIÓN QUE PROPORCIONAN SE CLASIFICAN EN:

- MEDIDAS DE TENDENCIA CENTRAL.
- MEDIDAS DE DISPERSIÓN
- MEDIDAS DE FORMA.

NOTA: EN ESTE CURSO SE VERÁ CÓMO REALIZAR EL CÁLCULO DE LAS MEDIDAS NÚMÉRICAS PARA DATOS NO AGRUPADOS (DNA) Y PARA DATOS AGRUPADOS (DA).

- NO AGRUPADOS → PUEDEN ESTAR ORDENADOS.
- AGRUPADOS → YA ESTÁN EN LA TABLA DE DISTRIBUCIÓN DE FRECUENCIAS.

MEDIDAS DE TENDENCIA CENTRAL: SON VALORES REPRESENTATIVOS DE UN CONJUNTO DE DATOS, QUE SE SITUAN EN LA PARTE CENTRAL DE LOS MISMOS.

MEDIA

MEDIA ARITMÉTICA O ESTADÍSTICO DE LA MEDIA (\bar{x})

LA MEDIA ARITMÉTICA ES MÁS CONOCIDA SENCILLOMENTE COMO MEDIA, Y ES EL PROMEDIO DE UN CONJUNTO DE VALORES. ES SIN DUDA LA MEDIDA DE TENDENCIA CENTRAL MÁS UTILIZADA, Y POR LO GENERAL LA MÁS REPRESENTATIVA.

$$\bar{x} = \begin{cases} \frac{1}{n} \sum_{i=1}^n x_i & ; \text{Datos no agrupados} \\ \frac{1}{n} \sum_{i=1}^m x_i f_i & ; \text{Datos agrupados} \end{cases}$$

m = clases o intervalos
 n = elementos

Narca
close

Frecuencia

EJEMPLO: DATOS NO AGRUPADOS

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{50} (30 + 31 + 36 + 40 + \dots + 77 + 77 + 79 + 79 + 80 + 82)$$

EXPRESAR PRIMEROS
CINCO

ULTIMOS CINCO

$$\bar{x} = 58,7$$

PARA DATOS AGRUPADOS:

$$\bar{x} = \frac{1}{50} [32,5(4) + 40,5(5) + 48,5(9) + 56,5(8) + 64,5(8) + 72,5(10) + 80,5(6)]$$
$$\bar{x} = 58,9$$

MEDIA GEOMÉTRICA. (G) (NO USAN LOS PÓSITOS)

LA MEDIA GEOMÉTRICA DE UN CONJUNTO DE VALORES POSITIVOS SE CALCULA CON LA RAÍZ n -ÉSIMA DEL PRODUCTO DE LAS n OBSERVACIONES.

$$G = \begin{cases} \sqrt[n]{x_1 x_2 \dots x_n}; & \text{DATOS NO AGRUPADOS} \\ \sqrt[n]{x_1^{f_1} x_2^{f_2} \dots x_m^{f_m}}; & \text{DATOS AGRUPADOS.} \end{cases}$$

$$\text{DNA } G = \sqrt[50]{30 \cdot 30 \cdot 31 \cdot 36 \cdot 41 \dots 77 \cdot 79 \cdot 79 \cdot 80 \cdot 82}$$

$$G = \sqrt[50]{30,5^4 \cdot 40,5^5 \cdot 48,5^9 \cdot 56,5^8 \cdot 64,5^8 \cdot 72,5^{10} \cdot 80,5^6}$$

(INCISO 1)

CECAYA

MEDIA ARMONICA. (H)

LA MEDIA ARMONICA DE UN CONJUNTO DE DATOS, ES EL RECIPROCO DE LA MEDIA ARITMETICA DE LOS RECIPROCIOS DE CADA UNO DE LOS VALORES.

$$H = \left\{ \begin{array}{l} \frac{1}{\frac{1}{n} \sum_{i=1}^n \frac{1}{x_i}} = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}} ; \text{ DATOS NO AGRUPADOS} \\ \frac{1}{\frac{1}{n} \sum_{i=1}^m \frac{f_i}{x_i}} = \frac{n}{\sum_{i=1}^m \frac{f_i}{x_i}} ; \text{ DATOS AGRUPADOS} \end{array} \right.$$

MEDIA PONDERADA (MP)

ES UNA MEDIDA DE TENDENCIA CENTRAL, QUE ES APROPIADA CUANDO EN UN CONJUNTO DE DATOS CADA UNO DE ELLOS TIENE UNA IMPORTANCIA RELATIVA (O PESO) RESPECTO DE LOS OTROS DATOS.

$$MP = \frac{\sum_{i=1}^n x_i w_i}{\sum_{i=1}^n w_i}$$

EJEMPLO: OBTENER EL PROMEDIO DE JAVIER PEREZ EN LA ASIGNATURA DE ESTADISTICA SI OBTUVO 6 EN EXAMEN, 7 EN TAREAS Y 8 EN PARTICIPACION.

$$MP = \frac{6(60) + 7(30) + 8(10)}{60 + 30 + 10} = \frac{620}{100} = 6.2$$

MEDIANA (\tilde{x}): LA MEDIANA DE UN CONJUNTO DE DATOS ORDENADOS, ES EL VALOR QUE DIVIDE AL CONJUNTO DE DATOS EN DOS CONJUNTOS DE IGUAL TAMAÑO, O BIEN ES EL PROMEDIO DE LOS DOS VALORES CENTRALES.

CUANDO LOS DATOS NO ESTAN AGRUPADOS, SE DEBE ORDENAR EN FORMA ASCENDENTE O DESCENDENTE Y SELECCIONAR EL VALOR CENTRAL. SI LOS DATOS SON PARES, ENTonces SE Toma EL PROMEDIO DE LOS VALORES CENTRALES; SI LOS DATOS SON IMPARES ENTONES SE Toma EL VALOR CENTRAL.

TOMANDO VALORES DE TABLAS:

$$\frac{50}{2} = 25 \quad \tilde{x}_1 = \text{POSICIÓN}$$

\tilde{x} - MEDIANA

$$\tilde{x} = (60 + 60) / 2 = 60$$

30, 31, 32, 36, 40, 41, 42, 43, 44, 45

45, 46, 48, 49, 49, 49, 49, 51, 53, 55

56, 56, 56, 59, 60, 60, 62, 63, 64, 64

64, 66, 67, 67, 69, 69, 70, 71, 72, 72

73, 73, 76, 76, 77, 77, 79, 79, 80, 82

CUANDO LOS DATOS ESTAN AGRUPADOS, ENTONES SE REALIZA UNA INTERPOLACION LINEAL UTILIZANDO LAS FRONTERAS Y LA FRECUENCIA ACUMULADA (ES DECIR LOS DATOS DE LA QJNA), PARA ENCONTRAR EL VALOR EN EL CUAL LA FRECUENCIA ACUMULADA ES DE $n/2$

$$y = \frac{(x - x_1)}{(x_2 - x_1)} (y_2 - y_1) + y_1$$

FRONTERA	FRECUENCIA F.
$y_1 = 52.5$	$x_1 = 18$
$y = x$	$x = 25 \rightarrow n/2 = 50/2 = 25$
$y_2 = 60.5$	$x_2 = 26$

$$y = 7 + 52.5$$

$$y = 59.5$$

MODA (x_m): LA MODA DE UN CONJUNTO DE DATOS ES EL VALOR QUE SE REPITE CON MAYOR FRECUENCIA.

PARA DATOS SIN AGRUPAR, SE DEBE CONTAR LAS REPETICIONES QUE PLEDAN EXISTIR Y EL QUE SE REPITA MAYOR NÚMERO DE VECES SERÁ LA MODA. SI TODOS LOS DATOS APARECEN EL MISMO NÚMERO DE VECES, ENTONES SE DICE QUE NO EXISTE MODA. (ANODAL)

$$x_m = 49$$

PARA DATOS AGRUPADOS, LA MODA SE APROXIMA CON LA MARCA DE CLASE DEL INTERVALO CON MAYOR FRECUENCIA, O BIEN, UTILIZANDO LA FÓRMULA:

$$x_m = \text{FRONTERA INFERIOR} + \left(\frac{\Delta_1}{\Delta_1 + \Delta_2} \right) c$$

CECAYA

DONDE $\hat{x}_{\text{inferior}}$ ES LA FRONTERA INFERIOR DEL INTERVALO CON MAYOR FRECUENCIA.

Δ_1 = ES EL EXCESO DE LA FRECUENCIA MODAL SOBRE LA FRECUENCIA DE LA CLASE INMEDIATA ANTERIOR.

Δ_2 = ES EL EXCESO DE LA FRECUENCIA MEDIAL Sobre LA FRECUENCIA DE LA CLASE INMEDIATA POSTERIOR

$$\bar{x}_{mo} = 68.5 + \left(\frac{(10-8)}{(10-8) + (10-6)} \right) (8) = 71.16$$

4 NOS IMPORTA LAS FRECUENCIAS DE LAS CLASES
5 SI HAY INTERVALOS CON FRECUENCIA IGUAL
9 ENTONES TOMAMOS LA PRIMERA.

$$68.5 = \frac{1}{10} \sum_{i=1}^{10} x_i \quad \text{or} \quad \sum_{i=1}^{10} x_i = 685$$

¿ES UNA MEDIA ARITMÉTICA LA MEDIDA QUE MEJOR REPRESENTA A LOS DATOS SIEMPRE? R. POR LO GENERAL, PERO NO SIEMPRE

EMPLEADO	SACARIO MENSUAL	$\bar{x} = 25,740$
1	\$ 8,000	2
2	\$ 12,700	4
3	\$ 6,500	1
4	\$ 92,000	5 (DATO ATIPICO)
5	\$ 9,500	3

UNIDAD DE DATOS

CUANTILES: ASÍ COMO LA MEDIANA ES EL VALOR QUE DIVIDE A UN CONJUNTO DE DATOS ORDENADOS DE IGUAL TAMAÑO EN DOS CONJUNTOS, LOS DATOS PUEDEN DIVIDIRSE EN 4 CONJUNTOS DE IGUAL TAMAÑO (**CUARTILES**), EN 10 CONJUNTOS DE IGUAL TAMAÑO (**DECILES**) Y EN 100 CONJUNTOS DE IGUAL TAMAÑO (**PERCILES**).

SIEMPRE ORDENAR DE MENOR A MAYOR LOS DATOS.

NOS SERVIRÁ PARA DISCRIMINAR DATOS O NO.

	número par	número impar
CUARTILES	$Q_k = \frac{kn}{4}$	$Q_k = \frac{k(n+1)}{4}$
DECILES	$D_k = \frac{kn}{10}$	$D_k = \frac{k(n+1)}{10}$
PERCENTILES	$P_k = \frac{kn}{100}$	$P_k = \frac{k(n+1)}{100}$

$$K = 1, 2, 3$$

$$K = 1, \dots, 9$$

$$K = 1, \dots, 99$$

OJO: EL VALOR CALCULADO CON ESTA FÓRMULA NOS INDICA LA POSICIÓN DEL CUANTIL, NO EL VALOR DEL MISMO.

OBTENER LA POSICIÓN DEL VALOR ENTERO MÁS LA POSICIÓN DEL VALOR ENTERO MÁS UNO, MENOS LA POSICIÓN ENTERA.

$$\text{CUANTIL} = \frac{\bar{x}_{\text{ENTERA}} + (\bar{x}_{\text{DECIMAL}}) \left(\frac{x_{\text{ENTERO+1}} - x_{\text{ENTERO}}}{\text{DATO}} \right)}{\text{POSICION}}$$

$$P_{97} = 80,44 = 82 + (0,44)(84 - 82)$$

$$P_{97} = 82,88$$

MEJIDAS DE DISPERSIÓN

CÉLAYA

LAS MEDIDAS DE DISPERSIÓN PROPORCIONAN UN INDICADOR DE ALEJAMIENTO DE LOS DATOS. TAMBÍEN SE LES LLAMA MEDIDAS DE VARIACIÓN.

RANGO, DESVIACIÓN MÉDIA, DESVIACIÓN MEDIANA, VARIANZA, DESVIACIÓN ESTÁNDAR, RAGC INTERCUARTILICO.

COEFICIENTE DE VARIACIÓN

CUANDO TENENCS DOS MUESTRAS
O POBLACIONES

COVARIANZA

RANGO: (R) ES LA DIFERENCIA ENTRE EL MAYOR VALOR MENOS EL VALOR MENOR. PARA DATOS AGRUPADOS SE UTILIZAN LOS LÍMITES MAYOR Y MENOR. ES COMÚN. ES COMÚN NO UTILIZAR LA OPERACIÓN DE RESTA Y SOLAMENTE INDICARLA.

$$R = \begin{cases} V_{\text{MAYOR}} - V_{\text{MENOR}} & \text{DNA} \\ L_{\text{MAYOR}} - L_{\text{MENOR}} & \text{DA} \end{cases}$$

DNA = $82 - 30 = 52$
DA = $84 - 29 = 55$

DESVIACIÓN MEDIA (DM): LA DESVIACIÓN MEDIA O DESVIACIÓN PROMEDIO DE UN CONJUNTO DE DATOS ES EL PROMEDIO DE LAS DISTANCIAS DE CADA VALOR CON RESPECTO A LA MEDIA.

$$DM = \begin{cases} 1/n \sum_{i=1}^n |x_i - \bar{x}| & \text{DNA} \\ 1/n \sum_{i=1}^n |x_i - \bar{x}| f_i & \text{DA} \end{cases}$$

$(52 + 12) / 10 = 6.4$
 $\hookrightarrow \text{Nota de clase}$

NÚMERO MÁGICO DE ESTADÍSTICA = 30

TANTO LA DESVIACIÓN MEDIA COMO LA DESVIACIÓN MEDIANA SON POCO UTILIZADAS EN LA PRÁCTICA POR LO DIFÍCIL DE MANEJAR EL VALOR ABSOLUTO. PARA ELIMINAR EL SIGNO DE LAS DIFERENCIAS DE $(x_i - \bar{x})$ Y EVITAR EL CÁLCULO ABSOLUTO SE DEFINE LA VARIANZA O VARIANCIA UTILIZANDO EL CUADRADO DE LAS DIFERENCIAS.

VARIANZA s^2 o s_{n-1}^2 DEPENDEN DEL VALOR QUE SE USO PARA PROMEDIAR

SE DIVIDE ENTRE n CUANDO SE CONSIDERA QUE SE TIENE TODOS LOS DATOS POSIBLES (POBLACIÓN), Y SE DIVIDE ENTRE $n-1$ CUANDO SE TIENE SÓLO UNA FRACCIÓN DE LOS DATOS (MUESTRA). LA FÓRMULA PARA LA VARIANZA ES:

$$s_{n-1}^2 = \begin{cases} \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 & ; \text{ DNA} \\ \frac{1}{n} \sum_{i=1}^m (x_i - \bar{x})^2 f_i & ; \text{ DA} \end{cases}$$

"VARIANZA POBLACIONAL"

$$s_{n-1}^2 = \begin{cases} \frac{1}{(n-1)} \sum_{i=1}^n (x_i - \bar{x})^2 & ; \text{ DNA} \\ \frac{1}{(n-1)} \sum_{i=1}^m (x_i - \bar{x})^2 f_i & ; \text{ DA} \end{cases}$$

"VARIANZA MUESTRAL."

OJO: SI LA MUESTRA ES MAYOR A 30 SE CONSIDERA GRANDE.

ES DECIR QUE A PARTIR DE UN TAMAÑO DE MUESTRA IGUAL O MAYOR A 30 ($n \geq 30$) PODEMOS OCUPAR LA PRIMERA FÓRMULA, YA QUE LOS RESULTADOS SON MUY Semejantes ENTRE ANOTACIONES Y CRONULAS,

PARA DA.

$$s_{n-1}^2 = \frac{1}{49} [(32.5 - 58.9)^2 (4) + (40.5 - 58.9)^2 (5) + (48.5 - 58.9)^2 (9) + (56.5 - 58.9)^2 (8) + (64.5 - 58.9)^2 (8) + (72.5 - 58.9)^2 (10) + (80.5 - 58.9)^2 (6)]$$

$$s_{n-1}^2 = 212.2449$$

CECAYA

DESVIACIÓN ESTÁNDAR (S_n) (SE ALEJAN LOS DATOS DE LA MÉDIA)

LA DESVIACIÓN ESTÁNDAR DE UN CONJUNTO DE DATOS ES LA RAÍZ CUADRADA DE LA VARIANZA. SE DENOTA POR S_n O POR S_{n-1}, DEPENDIENDO DE SI SE OBTIENE LA DESVIACIÓN ESTÁNDAR DE UNA MUESTRA O DE TODA LA POBLACIÓN.

ES CLARO QUE PARA CALCULAR LA DESVIACIÓN ESTÁNDAR DEBE CALCULARSE LA VARIANZA PRIMERO, DE FORMA QUE:

$$S_n = \sqrt{S_n^2} \quad S_{n-1} = \sqrt{S_{n-1}^2} \quad S_{n-1}^2 = \sqrt{212.24} = 14.56$$

RANGO INTERCUARTILICO (RQ) EL RANGO INTERCUARTILICO DE UN CONJUNTO DE DATOS ES LA DIFERENCIA ENTRE EL TERCER Y EL PRIMER CUARTIL.


$$RQ = Q_3 - Q_1$$

$RQ = 70.5 - 43$ (SE TONAN LOS VALORES DE LOS CUARTILES Y SE DEJA EXPRESADO)
(NOS DICE 50% DE LOS DATOS AL CENTRO)

NOS SIRVE PARA CONOCER LA MITAD DE LOS DATOS MÁS CERCA DE LA MÉDIA. EL RANGO SEMI-INTERCUARTILICO ES EL PRONEDIC DEL RANGO INTERCUARTILICO, ESTO ES.

$$Q = \frac{Q_3 - Q_1}{2} \quad (25\% \text{ DE LOS DATOS AL CENTRO})$$

DIAGRAMA DE CAJA (DATOS HOSPITAL) (DNA)



RANGO Q
CUARTILES Q₁, Q₂, Q₃
MEDIANA \bar{x}
MEDIANA (X)

BIGOTES.

$$1.5 \times \text{RANGO INTERCUARTILICO} = 38.25$$

VALOR DONDE TERMINAN BIGOTES

$$Q_1 - 1.5 \times RQ$$

$$Q_3 + 1.5 \times RQ$$

CUANDO TENEMOS DOS MUESTRAS O POBLACIONES ES JUSTAMENTE PARA COMPARARLAS, BUSCAMOS SI VARIAN O DEPENDEN UNA DE LA OTRA.

COEFICIENTE DE VARIACION (CV) (CUANTO VARIAN)

NOS AyUDA A COMPARAR LA VARIACION DE 2 CARACTERES QUE PUEDE SER MUY DIFERENTES. LA ECUACION PARA CALCULARLO ES LA SIGUIENTE.

$$CV = \frac{S_n}{\bar{x}}$$

CV. POBLACIONAL

$$CV = \frac{S_{n-1}}{\bar{x}}$$

CV. MUESTRAL

EJEMPLO: AÑOS DE ESTUDIO Y SUELDO DE 5 PERSONAS Y QUEREMOS SABER CUAL VARIA MAS.

AÑOS DE ESTUDIO	SUELOS
-----------------	--------

12	\$ 7,900
30	\$ 12,000
15	\$ 11,500
25	\$ 14,300
10	\$ 10,700

$$\bar{x} = 18.4$$

$$\bar{y} = 11,180$$

$$S^2_{n-1} = 75.3$$

$$S^2_{n-1} = 5,557,000$$

$$S_{n-1} = 8.67$$

$$S_{n-1} = 2,357$$

$$CV = \frac{8.67}{18.4}$$

$$CV = \frac{2,357}{11,180}$$

$$CV = 0.4712$$

$$CV = 0.2108$$

CONCLUSION: AÑOS DE ESTUDIO VARIAN MAS.

CRITERIO

$CV > 0.15 \rightarrow$ DATOS HETEROGENEOS } CON ESTO CONCLUIDOS CUANDO SOLO
 $CV \leq 0.15 \rightarrow$ DATOS HOMOGENEOS } TIENEN UNA MUESTRA.

COVARIANZA (COV) (DEPENDENCIA QUE EXISTE ENTRE DOS VARIABLES)

$$Cov(x, y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

$$\bar{xy} = 205,712$$

$$Cov = 11,648 \rightarrow$$
 DATOS DE ARRIBA.

- SI LA COVARIANZA ES POSITIVA, ESTO INDICA QUE LA DEPENDENCIA ES DIRECTA, EN CASO DE SER NEGATIVA, LA DEPENDENCIA ES INVERSA.

MEDIDAS NUMÉRICAS.

CECLAYA

MEDIDAS DE FORMA LAS MEDIDAS DE FORMA DE UN CONJUNTO DE DATOS SON EL SESGO Y LA CURTOSIS Y NOS MUESTRAN COMO SE DISTRIBUYEN LOS DATOS CON REFERENCIA A LA DISTRIBUCIÓN NORMAL.

PARA DEFINIR A LAS MEDIDAS, ES NECESARIO DEFINIR PRIMERO LOS MOMENTOS MOMENTO RESPECTO AL ORIGEN

EL r -ÉSIMO MOMENTO CON RESPECTO AL ORIGEN SE DEFINE MEDIANTE:

$$m_r = \begin{cases} \frac{1}{n} \sum_{i=1}^n x_i^r; & \text{DNA} \\ \frac{1}{n} \sum_{i=1}^m x_i^r f_i; & \text{DA} \end{cases}$$

MOMENTO CON RESPECTO A LA MEDIA

$$m_r = \begin{cases} \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^r; & \text{DNA} \\ \frac{1}{n} \sum_{i=1}^m (x_i - \bar{x})^r f_i; & \text{DA} \end{cases}$$

NOTA: DEBE OBSERVARSE QUE EL PRIMER MOMENTO CON RESPECTO AL ORIGEN m_1 ES LA MEDIA, MIENTRAS QUE EL SEGUNDO MOMENTO CON RESPECTO A LA MEDIA m_2 ES LA VARIANZA s_n^2

SESGO (α_3)

EL SESGO DE UN CONJUNTO DE DATOS ES LA MEDIDA DEL GRADO DE SIMETRÍA (O ASIMETRÍA) DE LOS DATOS. SE DENOTA POR α_3 Y SE DEFINE MEDIANTE

$$\alpha_3 = m_3 / s^3$$

DONDE m_3 ES EL TERCER MOMENTO CON RESPECTO A LA MEDIA Y s ES LA DESVIACIÓN ESTÁNDAR.

EJERCICIO PARA LOS DATOS QUE SE VIERON EN EL EJERCICIO ANTERIOR OBTENER EL SESGO PARA DATOS AGRUPADOS

$$m_3 = \frac{1}{50} [(32.5 - 58.9)^3(4) + \dots + (80.5 - 58.9)^3(6)]$$

$$S^3 = (14.56)^3 \Rightarrow \alpha_3 = \frac{-559.104}{3086.62} = -0.1811$$

EL SESGO SE COMPARA CON 0

- CUANDO EL COEFICIENTE DE SESGO ES MENOR QUE CERO SE DICE QUE LOS DATOS TIENEN UNA DISTRIBUCIÓN SESGADA A LA IZQUIERDA O CON SESGO NEGATIVO ($\alpha_3 < 0$)
- CUANDO EL COEFICIENTE DE SESGO ES POSITIVO SE DICE QUE LOS DATOS TIENEN UNA DISTRIBUCIÓN SESGADA A LA DERECHA O CON SESGO POSITIVO ($\alpha_3 > 0$)
- SI EL COEFICIENTE DE SESGO ES CERO, ENTonces LOS DATOS TIENEN UNA DISTRIBUCIÓN SIMÉTRICA O INSESGADA.

NOTA: PARA LAS MEDIDAS DE FORMA SE REQUIERE MENCIONAR QUE DISTRIBUCIÓN TIENEN LOS DATOS.

CURTOSIS (α_4)

EL COEFICIENTE DE CURTOSIS DE UN CONJUNTO DE DATOS MIDE EL GRADO DE APLANAMIENTO RELATIVO DE LA DISTRIBUCIÓN DE LOS DATOS. SE DENOTA MEDIANTE α_4 O POR α_4 . SE DEFINE MEDIANTE LA EXPRESIÓN.

$$\alpha_4 = \frac{m_4}{S^4} = \frac{m_4}{(S^2)^2}$$

EJERCICIO: PARA LOS DATOS QUE SE VIERON EN EL EJERCICIO ANTERIOR OBTENER LA CURTOSIS PARA DATOS AGRUPADOS.

$$\alpha_4 = \frac{85.554.78}{44.941.78}$$

$$m_4 = \frac{1}{50} [(32.5 - 58.9)^4(4) + \dots + (80.5 - 58.9)^4(6)]$$

$$S^4 = (14.56)^4$$

$$\alpha_4 = 1.8992$$

DECAYA

CRITERIO

LA CURTOSIS SE COMPARA CONTRA TRES, PORQUE TRES ES LA CURTOSIS DE LA DISTRIBUCIÓN NORMAL.

- SI LOS DATOS TIENEN UNA DISTRIBUCIÓN MÁS PUNTAJUDA QUE LA DISTRIBUCIÓN NORMAL $\alpha_4 > 3$ ENTONCES SE DICE QUE LOS DATOS TIENEN UNA DISTRIBUCIÓN LEPTOCÚRTICA.

- SI LOS DATOS TIENEN UNA DISTRIBUCIÓN COMO LA NORMAL, $\alpha_4 = 3$, ENTONCES SE DICE QUE LA DISTRIBUCIÓN ES NEUTROCÚRTICA.

- SI LOS DATOS TIENEN UNA DISTRIBUCIÓN APLANADA $\alpha_4 < 3$ ENTONCES RECIBE EL NOMBRE DE PLATOCÚRTICOS.

(SI LOS DATOS ESTAN ALJADOS O PEGADOS A LA MEDIA)
(LA CURTOSIS NO NOS PUEDE DAR UN VALOR NEGATIVO)

NOTA: PARA LAS MEDIDAS DE FORMA SE REQUIERE MENCIONAR QUE LA DISTRIBUCIÓN TIENEN LOS DATOS.

(α_4) PROBLEMA

$$\frac{E(X)}{\sigma^2} = \frac{E(X^2)}{\sigma^2} - \mu^2$$

$$[(0)^2(0.42 - 2.58) + \dots + (1)^2(0.42 - 2.58)] / 10 = 0.01$$

$$P(0 \leq X \leq 1) = 0.2$$

$$0.12 \cdot 0.2 = 0.024$$


$\leftarrow SP(X) = 0.024$

Norma

TEMA 2: CONCEPTOS BÁSICOS DE INFERENCIA ESTADÍSTICA.

INFERENCIA ESTADÍSTICA: LA INFERENCIA ESTADÍSTICA ES LA PARTE DE LA CIENCIA ESTADÍSTICA QUE TIENE POR OBJETO CONCLUSIONES ACERCA DE TODA UNA POBLACIÓN A PARTIR DE LA INFORMACIÓN CONTENIDA EN UNA MUESTRA, CUANTIFICANDO EN FORMA PROBABILÍSTICA EL GRADO DE CERTIDUMBRE DE ALCTAS CONCLUSIONES.

Y PARA OBTENER LA INFORMACIÓN QUE PERMITE GENERAR LAS CONCLUSIONES UTILIZA EL **MUESTREO ALEATORIO SIMPLE**, DEL CUAL SE OBTIENEN MUESTRAS REPRESENTATIVAS.



PARÁMETRO: UN PARÁMETRO ESTADÍSTICO ES UN NÚMERO QUE RESUMEN EL COMPORTAMIENTO DE UNA VARIABLE ALEATORIA Y QUE DESCRIBE PARCIAL O COMPLETAMENTE SU DISTRIBUCIÓN DE PROBABILIDAD.

LA MEDIDA μ Y LA VARIANZA σ^2 SON PARÁMETROS DE CUALQUIER V.A.

DEFINICIÓN: LAS V.A. X_1, X_2, \dots, X_n FORMAN UNA MUESTRA ALEATORIA DEL TAMAÑO n , SI SON INDEPENDIENTES Y TIENEN LA MISMA DISTRIBUCIÓN DE PROBABILIDAD.

A PARTIR DE ESTE MOMENTO, DEBEMOS TENER PRESENTE LAS CARACTERÍSTICAS DE INDEPENDENCIA E IDÉNTICA DISTRIBUCIÓN. (1.1, d)

RECORDATORIO: EN PROBABILIDAD SE VIO QUE ERA UNA VARIABLE ALEATORIA (V.A.) Y ES UNA FUNCIÓN CUYO DOMINIO ES EL ESPACIO MUESTRAL Y RANGO O CONTRADOMINIO UN SUBCONJUNTO DE LOS NÚMEROS REALES, SE SUELEN DENOTAR X, Y, Z → ESPACIO MUESTRAL.

$$X: S \rightarrow \mathbb{R}, \quad \mathbb{R} \in \mathbb{R}$$


$x_i \in X$ → VARIABLE
↓
DATOS

CADA DATO ES UNA REALIZACIÓN DE LA VA.

CECPAYA

ESTADÍSTICO: UN ESTADÍSTICO ES UNA FUNCIÓN DE LAS VA. QUE SE PUEDE OBSERVAR EN UNA MUESTRA Y QUE NO DEPENDE DE LOS PARÁMETROS DESCONOCIDOS.

LA MEDIA \bar{x} Y LA VARIANZA s^2 SON LOS ESTADÍSTICOS QUE MÁS SE UTILIZARÁN



- PARÁMETROS ESTADÍSTICOS
POBLACIONALES MUESTRALES

DISTRIBUCIÓN MUESTRAL DE LA MEDIA: DISTRIBUCIÓN NORMAL.

LA DISTRIBUCIÓN NORMAL SERVIRÁ PARA CARACTERIZAR LA DISTRIBUCIÓN MUESTRAL DE LA MEDIA

TEOREMA 1:

SI X_1, X_2, \dots, X_n SON VARIABLES ALEATORIAS INDEPENDIENTES, Y TODAS CON DISTRIBUCIÓN NORMAL CON MEDIA μ_i Y VARIANZA σ_i^2 , ENTONCES LA VARIABLE ALEATORIA Y (DEFINIDA COMO)

$$Y = X_1 + X_2 + \dots + X_n = \sum_{i=1}^n X_i$$

TIENE DISTRIBUCIÓN NORMAL CON MEDIA $\sum_{i=1}^n \mu_i$ Y VARIANZA $\sum_{i=1}^n \sigma_i^2$

TEOREMA 2:

SI X_1, X_2, \dots, X_n SON VARIABLES ALEATORIAS INDEPENDIENTES E IDÉNTICAMENTE DISTRIBUIDAS Y $X_i \sim N(\mu, \sigma^2)$ ENTONCES LA VARIABLE ALEATORIA

$$Y = \sum_{i=1}^n X_i$$

$$\text{TIENE DISTRIBUCIÓN NORMAL } Y \sim N(n\mu, n\sigma^2) \text{ POR LO QUE } \frac{Y - n\mu}{\sqrt{n}\sigma} \sim N(0, 1)$$

Normal

TEOREMA 3:

SI X_1, X_2, \dots, X_n SON VARIABLES ALEATORIAS INDEPENDIENTES Y TODAS CON DISTRIBUCIÓN NORMAL CON MEDIA μ_i Y VARIANZA σ_i^2 ENTONES LA VARIABLE ALEATORIA Y_c DEFINIDA COMO:

$$Y_c = c_1 X_1 + c_2 X_2 + \dots + c_n X_n = \sum_{i=1}^n c_i X_i$$

TIENE DISTRIBUCIÓN NORMAL CON MEDIA $\sum_{i=1}^n c_i \mu_i$ Y VARIANZA $\sum_{i=1}^n c_i^2 \sigma_i^2$

TEOREMA 4:

SEA X_1, X_2, \dots, X_n UNA MUESTRA ALEATORIA CON DISTRIBUCIÓN NORMAL Y MEDIDA μ Y VARIANZA σ^2 . ENTONES LA VARIABLE ALEATORIA

$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ TIENE DISTRIBUCIÓN NORMAL CON MEDIA μ Y VARIANZA σ^2/n .

$$\bar{X} \sim N(\mu, \sigma^2/n)$$

NOTA: LA PROPIEDAD DE ADITIVIDAD DE LA DISTRIBUCIÓN NORMAL PERMITE QUE LAS MEDIAS SE PUEDAN RESTAR, PERO LAS VARIANZAS SE SIGLEN SUMANDO, DEBIDO A LAS PROPRIEDADES DE LA SUMA DE VARIANZAS,

EJERCICIO 1

UN EJE DE DIÁMETRO EXTERIOR DISTRIBUIDO NORMALMENTE CON MEDIA 1.2 cm Y VARIANZA 0.0016 cm² SE INSERTA EN UN COJINETE QUE TIENE UN DIÁMETRO INTERIOR DISTRIBUIDO NORMALMENTE CON MEDIA 1.75 cm Y VARIANZA 0.0009 cm². DETERMINAR LA PROBABILIDAD DE QUE NO ENBONEN LAS PIEZAS.

$$X_1 \sim N(1.2, 0.0016) \quad X_2 \sim N(1.75, 0.0009)$$

PARA QUE NO ENBONEN $X_1 > X_2$ O BIEN $Y = X_1 - X_2 > 0$

$$Y \sim N(-0.55, 0.0025)$$

$$\frac{Y - \mu}{\sqrt{\sigma^2}} \sim N(0, 1)$$

POR LO QUE

$$P(Y > 0) = P\left(\frac{Y - (-0.55)}{\sqrt{0.0025}} > \frac{0 - (-0.55)}{\sqrt{0.0025}}\right)$$

$$P(Z > 1)$$

CUANDO NO NOS DIGAN TAMAÑO
NUESTRO $n = 1$.

TEOREMA

IMPORTANTES:

LOS TEOREMAS ANTERIORES SON ÚTILES SI SE DESEA OBTENER LA DISTRIBUCIÓN DE UNA SUMA DE VARIABLES ALEATORIAS DISTRIBUIDAS NORMALMENTE; SIN ENTIENDO, ESTO NO SIEMPRE OCURRE. EN GENERAL LAS VARIABLES ALEATORIAS PUEDEN TENER CUALQUIER DISTRIBUCIÓN Y NO SOLO LA NORMAL. CUANDO SE PRESENTAN ESTOS CASOS SE UTILIZA EL TEOREMA CENTRAL DE LÍMITES.

DISTRIBUCIÓN MUESTRAL DE LA MEDIA: TEOREMA CENTRAL DE LÍMITES.

SEAN X_1, X_2, \dots, X_n UN CONJUNTO DE VARIABLES ALEATORIAS INDEPENDIENTES E IDÉNTICAMENTE DISTRIBUIDAS CON PARÁMETROS $E(X_i) = \mu_X$ Y $\text{Var}(X_i) = \sigma^2_X$ PARA $i = 1, 2, \dots, n$. ENTONCES LA VARIABLE ALEATORIA \bar{X} DEFINIDA COMO $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$.

TIENE UNA DISTRIBUCIÓN QUE CONVERGE A LA NORMAL, CON PARÁMETROS $E(\bar{X}) = \mu_X$ Y $\text{Var}(\bar{X}) = \frac{\sigma^2_X}{n}$ ESTÁNDAR CUANDO $n \rightarrow \infty$, ESTO ES;

$$\bar{X} \sim N\left(E(\bar{X}) = \mu_X, \text{Var}(\bar{X}) = \frac{\sigma^2_X}{n}\right)$$

EN GENERAL, SI LAS n V.A. INDEPENDIENTES TIENEN PARÁMETROS $E(X_i) = \mu_i$ Y $\text{Var}(X_i) = \sigma^2_i$ Y SE DEFINE LA V.A. $Y = \sum_{i=1}^n X_i$ ENTONCES:

$$Y = \sum_{i=1}^n \mu_i$$

$$\sqrt{\sum_{i=1}^n \sigma^2_i}$$

TIENE DISTRIBUCIÓN QUE CONVERGE A LA NORMAL ESTÁNDAR. EN LA PRÁCTICA, EL TEOREMA CENTRAL DE LÍMITES PROPORCIONA UNA BUENA APROXIMACIÓN CUANDO n ES MAYOR O IGUAL A 30, SIN IMPORTAR LA DISTRIBUCIÓN DE LAS V.A. DE MUESTREO.

EL TEOREMA CENTRAL DE LIMITES SE APLICA SOLO A \bar{X} O A LA SUMATORIA

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

EJERCICIO 2.

LA RESISTENCIA A LA RUPTURA DE UN RENACHE ESPECIAL TIENE UN VALOR MEDIO DE 10,000 [kg] POR CENTÍMETRO CUADRADO Y UNA DESVIACIÓN ESTÁNDAR DE 500

- ¿CUÁL ES LA PROBABILIDAD DE QUE LA RESISTENCIA MEDIA A LA RUPTURA DE LA MUESTRA PARA UNA MUESTRA ALÉATORIA DE 40 RENACHES, SEA ENTRE 9900 Y 10200?
- SI EL TAMAÑO MUESTRAL HUBIERA SIDO 15 EN LUGAR DE 40, ¿PODRÍA CALCULARSE LA PROBABILIDAD PEDIDA EN EL INCISO (a)?

$$a) P(9900 \leq \bar{X} \leq 10200) = P\left(\frac{9900 - 10,000}{500/\sqrt{40}} \leq Z \leq \frac{10200 - 10,000}{500/\sqrt{40}}\right)$$

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} = P(-1.26 \leq Z \leq 2.53) = 0.8905$$

- CONO $n = 15$ SE REQUIERE CONOCER LA DISTRIBUCIÓN DE LA POBLACIÓN, YA QUE TAL SÓLO SE PUEDE UTILIZAR CON UN $n \geq 30$ NO SE PUEDE CALCULAR LA PROBABILIDAD.

CECAYA

EJERCICIO 3.

LA CANTIDAD PROMEDIO ECG GASTA UNA EMPRESA DURANTE UN AÑO EN SERVICIOS MÉDICOS POR CADA EMPLEADO FUE DE \$ 2 575 PESOS CON UNA DESVACIÓN ESTÁNDAR DE \$325 PESOS.


- a) ¿CUÁL ES LA PROBABILIDAD QUE A PARTIR DE UNA MUESTRA ALATORIA DE 70 EMPLEADOS SE OBSERVE UNA MEDIA MUESTRAL COMPRENDIDA ENTRE \$2500 Y \$2700? (QG DIFERENCIAS ENCUENTRA CON EL PROCESMA 4 DEL EJERCICIO 11.2?)
- b) ¿CUÁL ES LA PROBABILIDAD QUE A PARTIR DE UNA MUESTRA ALATORIA DE 100 EMPLEADOS SE OBSERVE UNA MEDIA MUESTRAL MENOR A \$2600?
- c) EL GERENTE DE UNA EMPRESA ASEGURO QUE GASTA UN PROMEDIO MÍNIMO ANUAL DE \$2 600 EN SERVICIOS MÉDICOS EN AL MENOS 90% DE SUS EMPLEADOS. ¿QUÉ TAMAÑO MÍNIMO DE LA MUESTRA DEBE ELEGIR EL GERENTE PARA CONFIRMAR SU AFIRMACIÓN DE MANERA ESTADÍSTICA?
- d) EL LIDER SINDICAL DE LA EMPRESA AFIRNA QUE LA EMPRESA GASTA UN PROMEDIO MÍNIMO ANUAL DE \$2 550 EN SERVICIOS MÉDICOS EN AL LO NAR 25% DE SUS EMPLEADOS. ¿QUÉ TAMAÑO MÍNIMO DE LA MUESTRA DEBE ELEGIR EL LIDER SINDICAL PARA CONFIRMAR DE MANERA ESTADÍSTICA SU AFIRMACIÓN?

a) $\mu = 2575 \quad \sigma_x = 325 \quad n = 70$

$$P(2500 \leq \bar{X} \leq 2700) = P\left(\frac{2500 - 2575}{325/\sqrt{70}} \leq z \leq \frac{2700 - 2575}{325/\sqrt{70}}\right)$$

$$= P(-1,9307 \leq z \leq 3,2179)$$

$$\Rightarrow 0,9923 - 0,0268 = 0,9725$$



∴ LA PROBABILIDAD DE ESTAR ENTRE 2500 Y 2700 PESOS ES 97,25%.

b) $n=100$ $P(\bar{X} < 2600) = ?$

$$P\left(Z < \frac{2600 - 2575}{325 / \sqrt{100}}\right) = P(Z < 0.7692)$$



DE TABLAS. $P(\bar{X} < 2600) = 0.7794$


LA PROBABILIDAD DE QUE LA MEDIA MUESTRAL CON $n=100$ SEA MENOR A 2600 ES 77.94%

c) $n=?$ $\bar{X}=2600$ $P(\bar{X} > 2600) \geq 0.9$

$$P\left(Z \geq \frac{2600 - 2575}{325 / \sqrt{n}}\right) = 0.9$$

BUSCAMOS Z EN TABLAS. 0.1 PORQUE LAS TABLAS DAN $<$

PARA $10\% = -1.282$ \rightarrow SOLO CAMBIA EL
PARA $90\% = 1.282$ \rightarrow SIGNO AL REVERSO
ES SIMETRICA



POB QUE ES MAYOR

\Rightarrow

$$\frac{-1.282 \cdot 325}{\sqrt{n}} = 2600 - 2575$$

∴ EL TAMAÑO MINIMO DE LA MUESTRA
ES DE 278 EMPLEADOS.

$$\left(\frac{-1.282 \cdot 325}{2600 - 2575} \right)^2 = n$$

$$n = 277.755$$

$n = 278$ PERSONAS \rightarrow REDONDEO SIEMPRE HACIA ARRIBA


NOTA: SIEMPRE QUE CALCULENOS UN TAMAÑO DE MUESTRA ES UNO MAS AL DIBUJO DE ESTADISTICA

Norma

CECAVIA

$$P(\bar{X} \geq 2550) \leq 0,25$$

$$P\left(Z \geq \frac{2550 - 2575}{325/\sqrt{n}}\right) \Rightarrow n \geq \left(\frac{-0,674 \cdot 325}{2550 - 2575}\right)^2$$




$$n \geq 76,77$$

$n \geq 77$ PERSONAS.

DISTRIBUCIÓN PARA CARACTERIZAR LA VARIANCIAS

POR LAS CARACTERÍSTICAS ESPECIALES QUE PRESENTA LA DISTRIBUCIÓN NORMAL, SE HAN ESTUDIADO DISTRIBUCIONES QUE PODEN GENERARSE A PARTIR DE ÉLLA, TAL ES EL CASO DE LA DISTRIBUCIÓN JI CUADRADA.



GRADOS DE LIBERTAD

$$v = (n - 1) \rightarrow \text{NÚMERO MUESTRAL} - 1$$

LA DISTRIBUCIÓN JI CUADRADA PRESENTA UN SESGO POSITIVO.

SEAN Z_1, Z_2, \dots, Z_v ; v VARIABLES ALÉATORIAS INDEPENDIENTES CON DISTRIBUCIÓN NORMAL ESTÁNDAR

$$X^2 = Z_1^2 + Z_2^2 + \dots + Z_v^2$$

ES UNA V.A. QUE RECIBE EL NOMBRE DE JI CUADRADA CON v GRADOS DE LIBERTAD. Y SE DENOTA MEDIANTE EL SÍMBOLO $\chi^2(v)$

SU FUNCIÓN DE DENSIDAD ES:

$$f_{\chi^2}(x) = \begin{cases} \frac{1}{2^{\frac{v}{2}} \Gamma(\frac{v}{2})} x^{\frac{(v-2)}{2}} e^{-\frac{x}{2}} & x > 0 \\ 0 & \text{e.o.c.} \end{cases}$$

TEOREMA 6

LA DISTRIBUCIÓN SI CUADRADA, AL IGUAL QUE LA DISTRIBUCIÓN NORMAL, PRESENTAN LAS CARACTERÍSTICAS DE SIMETRÍA Y ASIMETRÍA.

SEAN $X_1^2, X_2^2, \dots, X_n^2$ VARIABLES ALEATORIAS INDEPENDIENTES CON DISTRIBUCIÓN SI CUADRADA Y V_1, V_2, V_n GRADOS DE LIBERTAD, RESPECTIVAMENTE. ENTONCES LA VARIABLE

$$Y = X_1^2 + X_2^2 + \dots + X_n^2 = \sum_{i=1}^n X_i^2 \text{ TIENE DISTRIBUCIÓN SI CUADRADA}$$

$$\text{CON } V = \sum_{i=1}^n V_i$$

TEOREMA 7

SI X^2 ES UNA V.A. QUE TIENE DISTRIBUCIÓN SI CUADRADA CON V GRADOS DE LIBERTAD, $X^2 \sim \chi^2(V)$, ENTONCES.

$$E(X^2) = V, \text{ Var}(X^2) = 2V$$

y LA FUNCIÓN GENERADORA DE MOMENTOS DE X^2 ES:

$$M_{X^2}(\theta) = (1 - 2\theta)^{-\frac{1}{2}}$$

PARA CHARACTORIZAR A LA VARIANZA DE UNA MUESTRA O POBLACIÓN SE UTILIZA LA DISTRIBUCIÓN SI CUADRADA DE LA SIGUIENTE FORMA

VARIANCIA

$$\frac{nS^2}{6^2} \sim \chi^2(n-1)$$

✓ PARÁMETRO

$$n \geq 30$$

ESTADÍSTICO

$$\frac{(n-1)S^2}{6^2} \sim \chi^2(n-1)$$


$$n < 30$$

CECLAYA

EJERCICIO 4 Y 5.

a) Si $X^2 \sim \chi^2_{(15)}$ OBTENER $P(X^2 > 15.73)$


Por tablas $P(X^2 > 15.73) = 0.4$



b) Si $X^2 \sim \chi^2_{(20)}$, OBTENER $P(X^2 < 12.49)$

$$1 - P(X^2 > 12.49)$$

$$P(X^2 < 12.49) = 1 - 0.9 = 0.1$$



Ejercicio 6

SEA UNA MUESTRA ALEATORIA DE TAMAÑO 20 TOMADA DE UNA POBLACIÓN CON MEDIA 8 Y VARIANZA 4. OBTENER LA PROBABILIDAD DE QUE LA VARIANZA MUESTRAL S_{n-1}^2 SEA MAYOR O IGUAL A 5.7


$$n=20 \quad r=19 \quad M=8 \quad \sigma^2 = 4$$

$$P(S_{n-1}^2 \geq 5.7)$$

$$P\left(\frac{n-1}{6^2} S_{n-1}^2 \geq \frac{19}{4} (5.7)\right) = P(X^2 \geq 27.08)$$

DIRECTO DE TABLAS

$$P(X^2 \geq 27.08) = 0.1$$



DISTRIBUCIÓN PARA CARACTERIZAR A LA MEDIA MUESTRAL, MUESTRA PEQUEÑA, VARIANZA DESCONOCIDA.

TEOREMA 8. SEAN z y x^2 DOS VA. INDEPENDIENTES CON DISTRIBUCIÓN NORMAL ESTÁNDAR Y JI-CUADRADA RESPECTIVAMENTE, ES DECIR:

$$z \sim (0, 1), \quad x^2 \sim \chi^2(v)$$

ENTONCES LA VA T DEFINIDA COMO $T = \frac{z}{\sqrt{x^2/v}}$

TIENE UNA DISTRIBUCIÓN t DE STUDENT CON v GRADOS DE LIBERTAD y SU FUNCIÓN DE DENSIDAD DADA POR

$$f_T(t) = \frac{\Gamma\left(\frac{v+1}{2}\right)}{\sqrt{v} \Gamma\left(\frac{v}{2}\right)} \left(1 + \frac{t^2}{v}\right)^{-\frac{v+1}{2}} \quad -\infty < t < \infty$$

TEOREMA 9:

SI T ES UNA VARIABLE ALEATORIA QUE TIENE DISTRIBUCIÓN t - STUDENT CON v GRADOS DE LIBERTAD.

\Rightarrow

$$E(T) = 0 \quad \text{VAR}(T) = \frac{v}{v-2} \quad v > 2$$

COMO PUEDEN OBSERVARSE LA DISTRIBUCIÓN t DE STUDENT POSSE EL PARÁMETRO v, QUE AL IGUAL QUE PARA LA DISTRIBUCIÓN JI-CUADRADA, RECIBE EL NOMBRE DE GRADOS DE LIBERTAD.

LA FUNCIÓN DE DENSIDAD t DE STUDENT ES SIMÉTRICA Y UNIMODAL AL IGUAL QUE LA NORMAL, PERO SIEMPRE ESTÁ CENTRADA EN CERO; ES MUY PARECIDA A LA DISTRIBUCIÓN NORMAL ESTÁNDAR.

PARA CARACTERIZAR A LA MEDIA DE UNA MUESTRA PEQUEÑA CON VARIANZA DESCONOCIDA SE UTILIZA LA DISTRIBUCIÓN t-STUDENT DE LA SIGUIENTE FORMA.

$$\frac{\bar{X} - \mu_X}{\frac{S_{n-1}}{\sqrt{n}}} = T \sim t_{(n-1)}$$

Hoy se ha visto la distribución t-student, que es útil para inferencias estadísticas en el caso de que la muestra sea pequeña.

Ejercicio 8

Sea t una variable con distribución t-student, con 19 grados de libertad. Obtener:

$$7) P(T > 1.33)$$

8) El valor $b \in t$, tal que $P(T < b) = 0.01$

$$7) P(T > 1.33) = 0.10 \rightarrow \text{POR TABLAS}$$




$$8) P(T < b) = 0.01$$

$$P(T < b) = P(T > -b) = 0.01$$

$$-b = 2.539$$

$$b = -2.539$$

$$b > t = 0.01$$



Ejercicio 9

Los siguientes seis datos son los tiempos de permanencia (espera y atención) en un banco:

15, 32, 18, 26, 27 y 20
Si el banco afirma que el tiempo promedio de permanencia es de 20 minutos o menos, determinar si la afirmación es razonable.

$$\bar{x} = \frac{1}{6} (15 + 32 + 18 + 26 + 27 + 20) = 23$$

$$S_{n-1}^2 = \frac{1}{5} ((15-23)^2 + (32-23)^2 + (18-23)^2 + (26-23)^2 + (27-23)^2 + (20-23)^2)$$

$$S_{n-1}^2 = (6.387)^2$$

$$P(\bar{x} > 23) \Rightarrow P(T > \frac{23-20}{\sqrt{6.387}}) = P(T > 1.15) = 0.15 = 15\%.$$

NECESITAMOS ALZARNOS POR ESO ($>$) DE QUE LA MEDIA SEA IGUAL O MAYOR A 23.

∴ LOS DATOS NO PROPORCIONAN UNA FUERTE EVIDENCIA DE QUE EL BANCO NO TENGA RAZÓN, ES DECIR, LA AFIRMACIÓN DEL BANCO PUEDE SER RAZONABLE.

DISTRIBUCIÓN MULTINOMIAL.

ESCALA DE LICKERT → ESCALA DE SATISFACCIÓN → CUALITATIVAS

TS	S	NS	I	TI
4	3	2	1	

TS = TOTALMENTE SATISFECHO

TI = TOTALMENTE INSATISFECHO

PONDERAR # IMPAR PARA QUE ALIA PUNTO MEDIO.

SEAN X_1, X_2, \dots, X_n VARIABLES ALEATORIAS CONJUNTAS QUE REPRESENTAN EL NÚMERO DE ÉXITOS DEL PRIMER TIPO X_1 , EL NÚMERO DE ÉXITOS DEL SEGUNDO TIPO X_2 , ETC. CON $\sum_{i=1}^n X_i = n$ * ensayos que se obtiene en n ensayos independientes, cada uno de los cuales permite k resultados mutuamente excluyentes, cuyas probabilidades son P_1, P_2, \dots, P_k con $\sum_{i=1}^k P_i = 1$, entonces las v.a. TIENEN DISTRIBUCIÓN MULTINOMIAL CON PARÁMETROS n y P_1, P_2, \dots, P_k

$$f_{X_1, X_2, \dots, X_K}(x_1, x_2, \dots, x_n) = \frac{n!}{x_1! x_2! \dots x_n!} p_1^{x_1} p_2^{x_2} \dots p_k^{x_n}$$

PARA $X_i = 0, 1, \dots, n$; $1 \leq i \leq K$ y $\sum_{i=1}^n x_i = n$, $\sum_{i=1}^k p_i = 1$

EJEMPLO

SUPONGASE QUE UN PROCESO DE PRODUCCIÓN SE SELECCIONAN, DE MANERA ALEATORIA, 25 ARTÍCULOS. ESTE PROCESO POR LO GENERAL PRODUCE UN 90% DE ARTÍCULOS LISTOS PARA VENDERSE Y UN 7% REPROCESABLES. CUÁL ES LA PROBABILIDAD DE QUE 22 DE 25 ARTÍCULOS ESTÉN LISTOS PARA VENDERSE Y QUE SEAN REPROCESABLES?

$$n = 25$$

$$\text{ARTÍCULOS LISTOS PARA VENDERSE} = P_1 = 0.9$$

$$\text{ARTÍCULOS REPROCESABLES} = P_2 = 0.07$$

$$\text{ARTÍCULOS NO REPROCESABLES Y NO ESTÉN LISTOS} = 0.03$$

ENTONCES LAS VARIABLES TIENEN DISTRIBUCIÓN MULTINOMIAL POR LO QUE

$$P(X_1=22, X_2=2, X_3=1)$$

$$P(X_1=22, X_2=2, X_3=1) = \frac{25!}{22! 2! 1!} (0.9)^{22} (0.07)^2 (0.03)^1 = 0.0998 = 9.98\%$$

REGRESIÓN LINEAL

CECAYA. JAKONTUA INDRAPUR

LA REGRESIÓN PROPORCIONA LA POSIBLE RELACION ENTRE LAS VARIABLES DE UNA ECUACIÓN CON EL OBJETIVO DE PROPORCIONAR UNA DE LAS (VARIABLES DEPENDIENTE O VARIABLE DE SALIDA) EN FUNCION DE LA OTRA O OTRAS (VARIABLES INDEPENDIENTES O VARIABLES DE ENTRADA). EXISTEN DOS TIPOS DE REGRESIÓN EN GENERAL.

1) REGRESIÓN SIMPLE

2) REGRESSION MULTIPLE

LA REGRESIÓN SIMPLE SE UTILIZA CUANDO SE RELACIONAN DOS VARIABLES MIENTRAS QUE LA MÚLTIPLE SE UTILIZA PARA MÁS DE DOS VARIABLES. EN ESTE CURSO SE ESTUDIARÁ LA REGRESIÓN SIMPLE EN LA CUAL EL TIPO DE CURVA PUEDE SER, LINEAL, POLINOMIAL, EXPONENCIAL Y ALGUNOS OTROS MODELOS. EN ESTE TEMA NOS CONCENTRAREMOS EN EL ESTUDIO DE REGRESIÓN LINEAL SIN DICE HACIENDO LO QUE SE LLAMA ANÁLISIS ESTADÍSTICO BIVARIADO DENOMINADO ASÍ POR EL NÚMERO DE DOS COJUNTOS DE DATOS EL CASO MÁS COMÚN DE ANÁLISIS ESTADÍSTICO BIVARIADO ES EL AJUSTE POR MÍNIMOS CUADRADOS.

AJUSTE POR NIÑOS CUADRADOS.

PARTIENDO DE QUE SE DESEA OBTENER UN MODELO LINEAL PARA LA VARIABLE DEPENDIENTE ' y ' EN FUNCIÓN DE LA VARIABLE INDEPENDIENTE ' x ', SE ESCRIBE:

$$y = \beta_0 + \beta_1 x + \varepsilon$$

DONDE ϵ ES UN ERROR ALATORIO QUE SE OBTIENE DEBIDO AL MODELO SIN CONSIDERAR EL ERROR EL MODELO SE PUEDE ESCRIBIR COMO

$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$ → ESTIMADOR A PARTIR DE UNA MUESTRA.

DONDE LA PENDIENTE Y LA APERTURA AL ORIGEN TIENE UN ACENTO CIRCUNFLEXO PARA INDICAR QUE SE TRATA DE APROXIMACIONES DE LOS VERDADEROS PARÁMETROS.

(x) (y)
CONSIDERANDO EL VALOR REAL Y EL APROXIMADO PARA CADA DUNTO OBTENER
LA SUMA DE ERRORES CUADRADOS.

$$SSE = \sum_{i=1}^n \hat{e}_i^2 = \sum_{i=1}^n (y_i - \hat{y})^2 \rightarrow \text{DISTANCIAS} = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

USAR VALORES REALES



$$\frac{\partial \text{SEC}}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) \quad \frac{\partial \text{SEC}}{\partial \beta_1} = -2 (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)$$

DE DONDE

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

X	Y	X^2	Y^2	XY

O BIEN $\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - \left(\sum_{i=1}^n y_i\right) \left(\sum_{i=1}^n x_i\right)}{\sum_{i=1}^n x_i^2 - \frac{\left(\sum_{i=1}^n x_i\right)^2}{n}}$

$\sum \text{MULTIPLICACIÓN DE } X \text{ Y } Y = SS_{xy}$
 $\sum \text{SUMA DE LA MULTIPLICACIÓN DE } X \text{ CON } X$
 $x^2 = SS_{xx}$

$$\hat{\beta}_1 = m$$

SIMPLIFICANDO NOTACIÓN

$$SS_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad SS_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$$


$$\Rightarrow \hat{\beta}_1 = \frac{SS_{xy}}{SS_{xx}}$$

$\hat{\beta}_0$ y $\hat{\beta}_1$ SON ESTIMADORES (APROXIMADORES) INSERGADOS DE β_0 y β_1 , QUE SON LOS PARÁMETROS QUE SE DESEA OBTENER.

CABE Aclarar que la ecuación de regresión que se obtenga es válida solo para parejas comprendidas en el rango dentro del experimentado.

DIAGRAMA DE DISPERSIÓN

UNA VEZ QUE SE HA DETERMINADO LA ECUACIÓN DE REGRESIÓN, ES ÚTIL LA REPRESENTACIÓN GRÁFICA DE LOS PUNTOS DE DATOS EN EL PLANO Y EN LO QUE SE DENOMINA DIAGRAMA DE DISPERSIÓN. CUANDO LA REGRESIÓN ES LINEAL, LOS PUNTOS DEBEN MOSTRAR ESA TENDENCIA, AUN QUE NO DEBE ESPERARSE QUE LOS PUNTOS SE UBICUEN EXACTAMENTE EN UNA RECTA.



CECAVIA

$$\sum (y_i - \bar{y})^2 = \text{SEC} = \text{SUMA DE ERRORES AL CUADRADO}$$

COVARIANZA:

$$\text{Cov} = \frac{\text{SS}_{xy}}{n} = \frac{\sum xy - \frac{\sum x \sum y}{n}}{n}$$


COEFICIENTE DE DETERMINACIÓN

EL COEFICIENTE DE DETERMINACIÓN LINEAL r^2 DE LA MUESTRA ES:

$$r^2 = \frac{\text{SS}_{xy}^2}{\text{SS}_x \cdot \text{SS}_y}$$

y REPRESENTA LA PROPORCIÓN DE VARIACIÓN DE y OBSERVADA QUE SE EXPLICA MEDIANTE EL MODELO DE REGRESIÓN.

SI EL VALOR DE y ES INDEPENDIENTE DE x , ENTONCES EL VALOR MÁS REPRESENTATIVO DE y SERÍA \bar{y} , Y PARA CADA VALOR REAL y_i SE OBTENDRÍA UN ERROR CON RESPECTO DE \bar{y} .




$$\sum (y_i - \bar{y})^2 = \text{SS}_{yy}$$

\Rightarrow LA SUMA DE ESTOS ERRORES ESTÁ DADO POR

$$\text{SS}_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2$$

MIENTRAS QUE AL REPARTIR EL AJUSTE A UNA RECTA POR MÍNIMOS CUADRADOS, EL ERROR SE OBTIENE CON LA RECTA DE AJUSTE $\hat{y} = \hat{B}_0 + \hat{B}_1 x$ Y LA SUMA DE LOS ERRORES AL CUADRADO ES



$$\text{SEC} = \sum_{i=1}^n (y_i - \hat{y})^2$$

ES CLARO QUE SEC ES UNA PROPORCIÓN MENOR O IGUAL A UNO, E INDICA LA VARIACIÓN QUE EL MODELO NO ACLARA SS_{yy} O NO EXPLICA. SI $\text{SEC}/\text{SS}_{yy} = 0$, ENTÓNCEZ $\text{SEC} = 0$ Y LOS PUNTOS EXPERIMENTALES O OBSERVADOS ESTÁN CONTENIDOS TODOS SOBRE LA RECTA DE AJUSTE, POR LO QUE NO EXISTE VARIACIÓN NO EXPLICA. SI $\text{SEC}/\text{SS}_{yy} = 1$ ENTÓNCEZ $\text{SEC} = \text{SS}_{yy}$ Y LA RECTA OBTENIDA ES HORIZONTAL QUE COINCIDE CON \bar{y} . POR LO QUE EL MODELO NO EXPLICA NADA ADICIONAL AL PROMEDIO.

COEFICIENTE DE CORRELACIÓN

EL COEFICIENTE DE CORRELACIÓN PROPORCIONA EL GRADO DE ASOCIACIÓN LINEAL DE LAS VARIABLES X Y Y , EN OTRAS PALABRAS, EL COEFICIENTE DE CORRELACIÓN QUE SE ESTUDIA EN ESTE CURSO ES DE TIPO SIMPLE, ES DECIR, CONSIDERA SOLO DOS VARIABLES EN UNA LÍNEA LINEAL.

EL COEFICIENTE DE CORRELACIÓN DE LA MUESTRA ES:

$$r = \frac{SS_{xy}}{\sqrt{SS_{xx} SS_{yy}}}$$

y PROPORCIONA EL GRADO DE ASOCIACIÓN LINEAL DE LAS VARIABLES X Y Y

$$SS_{xy} = \sum_{i=1}^n x_i y_i - \frac{\sum_{i=1}^n x_i}{n} \cdot \frac{\sum_{i=1}^n y_i}{n}$$



$$SS_{yy} = \sum_{i=1}^n y_i^2 - \frac{(\sum_{i=1}^n y_i)^2}{n}$$

TIPOS DE CORRELACIÓN:


EXISTEN TRES TIPOS DE CORRELACIÓN

CORRELACIÓN DIRECTA O POSITIVA: SE OBTIENE CUANDO AL AUMENTAR (DISMINUIR)

EL VALOR DE LA VARIABLE INDEPENDIENTE AUMENTA (DISMINUYE) TAMBIÉN EL VALOR DE LA VARIABLE DEPENDIENTE. SI LA CORRELACIÓN TIENE EL VALOR DE 1 SE TIENE CORRELACIÓN POSITIVA PERFECTA.




CORRELACIÓN INVERSA O NEGATIVA. SE OBTIENE CUANDO AL AUMENTAR (DISMINUIR), EL VALOR DE LA VARIABLE INDEPENDIENTE DISMINUYE (AUMENTA) EL VALOR DE LA VARIABLE DEPENDIENTE. SI LA CORRELACIÓN TIENE EL VALOR DE -1 SE TIENE CORRELACIÓN NEGATIVA PERFECTA.



CECAYA

CORRELACIÓN NULA: SE DA CUANDO NO EXISTE RELACIÓN LINEAL ENTRE VARIABLES.



EJEMPLO

EMPLEA EL MÉTODO DE MENOS CUADRADOS PARA AJUSTAR LOS SIGUIENTES PUNTOS A UNA RECTA.

X	1	2	3	4	5	6	21	XY	1	4	6	12	25	30	78	y^2	1	4	9	25	25	68
Y	1	2	2	3	5	5	18	x^2	1	4	9	16	25	36	91	$n=6$	$\bar{x}=3,5$	$\bar{y}=3$				

- a) ¿Cuáles son las estimaciones de \hat{B}_0 y \hat{B}_1 de menores cuadrados?
b) OBTENER EL COEFICIENTE DE CORRELACIÓN E INTERPRETARLO.

$$SS_{xy} = 78 - \frac{(21)(18)}{6} = 15 \quad SS_{xx} = 91 - \frac{(21)^2}{6} = 17,5$$

$$SS_{yy} = 68 - \frac{(18)^2}{6} = 14 \quad \hat{B}_0 = \bar{y} - \hat{B}_1 \bar{x}$$

$$\hat{B}_1 = \frac{SS_{xy}}{SS_{xx}} = \frac{15}{17,5} = 0,8571$$

$$\hat{B}_0 = 3 - (0,8571)(3,5)$$

$$\hat{B}_0 = 1,5 \times 10^{-4} \approx 0$$

a) $\hat{y} = 0,8571x + 1,5$

b)

$$r = \frac{SS_{xy}}{\sqrt{SS_{xx}SS_{yy}}} = \frac{15}{\sqrt{(14)(17,5)}} = 0,9583$$

: Dependencia FUERTE

- c) OBTENER EL COEFICIENTE DE DETERMINACIÓN E INTERPRETARLO.

$$r^2 = \frac{SS_{xy}^2}{SS_{xx}SS_{yy}} = \frac{(15)^2}{(17,5)(14)} = 0,9184$$


∴ LA VARIABLE X EXPLICA
EL 91,84% DEL COMPORTAMIENTO
DE LA VARIABLE Y.

LOS SIGUIENTES DATOS REPRESENTAN EL NÚMERO DE HORAS DE ESTUDIO Y LA CALIFICACIÓN OBTENIDA EN UN EXAMEN, PARA UNA MUESTRA DE 6 ESTUDIANTES.

ESTUDIANTE	A	B	C	D	E	F
HORAS	1	2	4	4	7	12
CALIFICACIÓN	71	71	74	80	80	86

X	Y	71	142	296	320	560	1032	2471
x^2		1	4	16	16	49	144	230
y^2		5041	3041	5476	6400	6400	7396	35754

a) REPRESENTA LOS DATOS EN UN DIAGRAMA DE DISPERSIÓN:



b) AJUSTAR A LOS DATOS A UN MODELO LINEAL DE REGRESIÓN EMPLEANDO EL CRITERIO DE MENIMOS CUADRADOS

$$SS_{XY} = 2471 - \frac{(30)(462)}{6} = 111$$

$$SS_{XX} = 230 - \frac{(30)^2}{6} = 80$$

$$SS_{YY} = 35754 - \frac{(462)^2}{6} = 180$$

$$\bar{X} = \frac{30}{6} \quad \bar{Y} = \frac{462}{6}$$

$$\hat{B}_1 = \frac{SS_{XY}}{SS_{XX}} = \frac{111}{80} = 1,3875$$

$$\hat{B}_0 = \bar{Y} - \hat{B}_1 \bar{X}$$

$$\hat{B}_0 = \frac{462}{6} - 1,3875(30/6) = 70,0625$$

$$y = 70,0625 + 1,3875x$$

c) SI ESTUDIA 5 HORAS ¿CUÁL CALIFICACIÓN ESPERARÍA?

$$y(5) = 70,0625 + 1,3875(5)$$

$$y(5) = 73,75$$

c,2) SI QUIERO OBTENER 85 DE CALIFICACIÓN ¿CUÁNTAS HORAS DEBO ESTUDIAR?

$$x = \frac{y - 70,0625}{1,3875} \Rightarrow x = \frac{85 - 70,0625}{1,3875} = 10,7658$$

NOTA: PARA GRÁFICAR LA PECINA, USAR \hat{B}_0 = ORDENADA AL ORIGEN Y EL VALOR MAX. DE X CON LA ECUACIÓN PARA DESPUES UNIR LOS PUNTOS.

CG CAYA

d) CALCULAR LA COVARIANZA Y EL COEFICIENTE DE DETERMINACIÓN E INTERPRETAR LOS RESULTADOS DE LA RELACIÓN DE VARIABLES

$$\text{COV} = \frac{\text{SS}_{XY}}{n} = \frac{111}{8} = 18.5 \rightarrow \text{DEPENDENCIA DIRECTA}$$

$$r^2 = \frac{\text{SS}_{XY}^2}{\text{SS}_{XX} \text{SS}_{YY}} = \frac{(111)^2}{(80)(180)} = 0.8556 \rightarrow \begin{array}{l} \text{LA VARIABLE X EXPlica} \\ \text{EL 85.56 \% A LA} \\ \text{VARIABLE Y} \end{array}$$

e) COEFICIENTE DE CORRELACIÓN

$$r = \frac{\text{SS}_{XY}}{\sqrt{\text{SS}_{XX} \text{SS}_{YY}}} = \frac{111}{\sqrt{(80)(180)}} = 0.925 \rightarrow \begin{array}{l} \text{DEPENDENCIA FUERTE Y} \\ \text{POSITIVA} \end{array}$$

$$\lambda_1 = 2.520 \quad \lambda_2 = 0.479 \quad \lambda_3 = 0.000$$

$$\lambda_1 = 2.520 \quad \lambda_2 = 0.479 \quad \lambda_3 = 0.000$$

$$\lambda_1 = 2.520 \quad \lambda_2 = 0.479 \quad \lambda_3 = 0.000$$

Conceptos básicos sobre estimadores puntuales.

LOS PRINCIPIOS BÁSICOS DE LA INFERENCIA ESTADÍSTICA CONSISTEN EN CREAR MÉTODOS PARA REALIZAR CONCLUSIONES O INFERNCIAS Acerca DE LA POBLACIÓN.

EXISTEN 2 MÉTODOS (CLÁSICO Y BOYSENDO)

MÉTODO CLÁSICO: LA INFERNCIJA SE REALIZA POR MÉTODO DE LOS RESULTADOS DE LA MUESTRA ALEATORIA

MÉTODO BOYSENDO: LA INFERNCIJA SE LLEVA A EFECTO CON BASE EN EL CONOCIMIENTO PREVIO SOBRE LA DISTRIBUCIÓN DE LOS PARÁMETROS DESCONOCIDOS O EN LAS VARIABLES ALEATORIAS.

ESPACIO PARAMÉTRICO

DETERMINA EL CONJUNTO DE VALORES POSIBLES DE UN PARÁMETRO. SEA X_1, X_2, \dots, X_n UNA MUESTRA ALEATORIA CON FUNCIÓN DE DENSIDAD $f(x; \theta)$ DONDE LA FORMA DE LA FUNCIÓN ES CONOCIDA, POR EL PARÁMETRO θ DESCONOCIDO. SOLO SABEMOS QUE PERTENECE AL ESPACIO PARAMÉTRICO DENOTADO POR Ω .

EN LA INFERNCIJA ESTADÍSTICA AL HABLAR DEL PARÁMETRO HACEMOS REFERENCIA A UNA FAMILIA DE DENSIDADES. DEBEMOS ESTUDIAR LA FORMA DE OBTENER INFORMACIÓN DEL PARÁMETRO θ DE LA FUNCIÓN DE DENSIDAD f .

ESTIMADOR PUNTUAL.

CON BASE EN EL VALOR CALCULADO DE LA ESTADÍSTICA \bar{X} SE PUEDE LLEVAR A EFECTO UNA INFERNCIJA DEL PARÁMETRO μ , ES DECIR SE PUEDE HACER UNA ESTIMACIÓN PUNTUAL DEL PARÁMETRO.

CECAYA

SEA UNA POBLACION CON PARAMETRO θ ; X_1, X_2, \dots, X_n UNA MUESTRA ALATORIA DE LA POBLACION CON $\theta = \mu(X_1, X_2, \dots, X_n)$. LA ESTADISTICA CORRESPONDIENTE DE θ EN LA PARTE DE ESTIMACION DE θ MIENTRAS QUE EL VALOR DE θ SE OBTIENE AL REALIZACION DE LA MISMA ALATORIA SE LE LLAMA ESTIMADOR PUNTUAL DE θ .

CON ESTE SE DICE QUE SI θ ES EL PARAMETRO CON ESPACIO PARAMETRICO R CUANTO ESTIMADOR PUNTUAL DE θ PUEDE ESTAR CONTENIDO EN R .
ES DECIR SI $\mu(X_1, \dots, X_n)$ ES EL ESTIMADOR DEL PARAMETRO SU DISTRIBUCION TENDRA COMO DOMINIO A R . LA MAYORIA DE LOS ESTIMACIONES ESTAN RELACIONADAS CON LA MEDIA EN LA VARIANZA μ_{est} Y σ^2_{est}

ESTIMADORES INSESGADOS:

EN LA PROPIEDAD DESARROLLADA ESTIMADOR $\hat{\theta} = \mu(X_1, \dots, X_n)$ SE PREFERE CUANDO EL VALOR ESPERADO DE LA DISTRIBUCION DEL ESTIMADOR $\hat{\theta}$ ES IGUAL AL PARAMETRO θ . PARA PROBAR SI UN PARAMETRO ES INSESGADO UTILIZAMOS LA LINEALIDAD DEL VALOR ESPERADO.

$$E(a_1 X_1 + a_2 X_2 + \dots + a_n X_n) = a_1 E(X_1) + a_2 E(X_2) + \dots + a_n E(X_n)$$

UN ESTIMADOR $\hat{\theta} = (X_1, \dots, X_n)$ DE UNO.

FUNCION $g(\theta)$ DEL PARAMETRO θ SE LLAMA ESTIMACION INSESGADO DE $g(\theta)$ SI $E(\hat{\theta}) = g(\theta)$ EN CASO CONTRARIO $E(\hat{\theta}) \neq g(\theta)$ SE LLAMA ESTIMADOR SESGADO DE $g(\theta)$.

ESTADÍSTICOS SUFICIENTES

UNA DE LAS PREOCUPACIONES AL USAR ESTADÍSTICA ES EN EL COPL CONCENTRAR TOTA LA INFORMACIÓN CONTENIDA EN LA MUESTRA, ALCATORDIA RESPECTO AL PARÁMETRO DE ESTUDIO, ES DECIR SI TENEMOS UNA MUESTRA ALCATORDIA x_1, \dots, x_n CON FONCIÓN DE DENSIDAD CONJUNTO:

$$f(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f_{x_i; \theta}$$

LA ESTADÍSTICA QUE SE BUSCA DEBE BASARSE EN:

A) LA FORMA DE LA DENSIDAD f ,

B) EL ESPACIO PARAMÉTRICO Λ

C) LAS OBSERVACIONES DE LA MUESTRA, SI COMPLE CON ESTAS CARACTERÍSTICAS DE CE LLAMA ESTADÍSTICO SUFFICIENTE, EL SIGUIENTE TEOREMA NOS AYUDA A DETERMINAR SI TIENE ESTADÍSTICA SUFFICIENTE O NO.

TEOREMA:

CRITERIO DE FACTORIZACIÓN NEYMAN - FISHER

SEA x_1, \dots, x_n UNA MUESTRA ALCATORDIA DE UNA POBLACIÓN CON DENSIDAD $f(x; \theta)$ CON $\theta \in \Lambda$ Y SEA $T = V(x_1, \dots, x_n)$ UNA FUNCIÓN DE OBSERVACIONES, ENTONCES T ES UNA ESTADÍSTICA SUFFICIENTE PARA θ BASADO EN LA MUESTRA ALCATORDIA \Leftrightarrow LA DENSIDAD CONJUNTA

$$f(x_1, \dots, x_n; \theta) = f_T(T(x_1, \dots, x_n); \theta) H(x_1, \dots, x_n)$$

DONDE $H(x_1, \dots, x_n)$ ES UNA FUNCIÓN QUE NO DEPENDE DE θ

COROLARIO:

T ES UN ESTADÍSTICO SUFFICIENTE PARA θ SI

$\Psi_1: X \rightarrow t$; $\Psi_2(X_1, \dots, X_n)$ EN DONDE $\Psi_2(X_1, \dots, X_n)$ NO DEPENDE DE θ , ES CONVENIENTE USAR LA FONCIÓN INDICADA.

CECMYR

$$(ab) = \begin{cases} 1 & a \leq b \\ 0 & a > b \end{cases}$$

$$1_{ab} / |x| = \begin{cases} 1 & a \leq x \leq b \\ 0 & \text{else.} \end{cases}$$

PROPIEDAD DE INVARIANZA

SEAN x_1, \dots, x_n UNA MUESTRA ACEPATORIA DE UNA POBLACIÓN CON DENSIDAD $f(x; \theta)$ ($\theta \in \mathbb{R}$) Y $T = t(x_1, \dots, x_n)$ UNA ESTADÍSTICA SUFFICIENTE PARA EL PARÁMETRO EN LA MUESTRA ACEPATORIA Y SEA $g(\cdot)$ UNA FONCIÓN INVARIANTE DE t EN TÉRMINOS.

A) $g(T)$ ES UNA ESTADÍSTICA SUFFICIENTE PARA θ

B) T ES UNA ESTADÍSTICA SUFFICIENTE PARA $g(\theta)$

PARA DECIR QUE ESTIMADOR ES MÁS EFICIENTE SE TENDRÁ QUE CALCULAR LA VARIANZA POR TANTO

$$V(Q, x_1 + Q_1 x_2 + \dots + Q_n x_n) = Q_1^2(x_1) + Q_2^2(x_2) + \dots + Q_n^2(x_n)$$

DANO EL PARÁMETRO θ Y UN CONJUNTO DE ESTIMADORES INSERGADOS DE ESTE $\hat{\theta}_1, \hat{\theta}_2, \dots$ SE LLAMA ESTIMADOR MÁS EFICIENTE RECIPROCO DE θ RESPECTO DEL CONJUNTO DE ESTIMADORES INSERGADOS AL ESTIMADOR COUYA VARIANZA SEA MENOR.

ERROR CUADRADO MEDIO

SEAN x_1, \dots, x_n UNA MUESTRA ACEPATORIA DE DENSIDAD

$f(x; \theta)$ ($\theta \in \mathbb{R}$) Y $T = u(x_1, \dots, x_n)$ ESTIMADOR DE $g(\theta)$ SE DENOMINA ERROR CUADRADO MEDIO DE $g(\theta)$ RESPECTO DE $t = u(x)$

$$E_0 [T - g(\theta)^2] = \text{COCMO } T,$$

OBSEERVE QUE EL ERROR CUADRADO MEDIO SE PARECE AL
VALOR ESPERADO DEL CUADRADO DEL SESGO ($E(T) - g(\theta)$)
PERO EN LUGAR DEL VALOR ESPERADO TENEMOS AL
ESTIMADOR $T - g(\theta)$

SEA X_1, \dots, X_n UNA MUESTRA ALEATORIA DE UNA POBLACION
CON PARAMETRO θ , E FLEIR Y $T = (X_1, \dots, X_n)$
EL ESTIMADOR DE $g(\theta)$

$$\text{COCMO}(T) = V_0(T) + S_0^2 T$$

DONDE $V_0(T)$ Y $S_0(T)$ SON LA VARIANZA Y EL SESGO DE
 T CON PARAMETRO θ RESPECTIVAMENTE.

PROPIEDADES ASINTOTICAS DESGRADABLES DE LOS ESTIMADORES

① ESTIMADORES CONSISTENTES:

SEA UNA MUESTRA ALEATORIA X_1, X_2, \dots, X_n TOMADA DE
UNA POBLACION CON PARAMETRO θ DENCENES
A UN ESTIMADOR DE $g(\theta)$ POR T_n BASADO EN LA
MUESTRA DECIMOS QUE T_n ES UN ESTIMADOR
CONSISTENTE PARA $g(\theta)$ SI LA MEDIDA QUE AUMENTA
 n AUMENTA LA PRECISION DE T_n AUMENTA.

POR EJEMPLO:

$$\bar{X} \xrightarrow[n \rightarrow \infty]{\longrightarrow} \mu \quad \text{DE MANERA SIMILAR} \quad S^2 \xrightarrow[n \rightarrow \infty]{\longrightarrow} \sigma^2$$

CECAYA

② ESTIMADORES CONSISTENTES EN PROBABILIDAD.

SEA UNA MUESTRA ALATORIA X_1, X_2, \dots, X_n TOMADA DE UNA POBLACIÓN CON PARÁMETRO θ Y CONSIDERAMOS UNA SUCCECIÓN DE ESTIMADORES

$\{T_n\}_{n \geq 1}$, de $g(\theta)$ BASADOS EN LA MUESTRA DECIMOS QUE LA SUCCECIÓN ES CONSISTENTE EN PROBABILIDAD A $g(\theta)$ SI SE ROMPE LA CONVERGENCIJA EN PROBABILIDAD

PARA CUALQUIER $\epsilon > 0$ SE COMPROVE QUE:

$$\lim_{n \rightarrow \infty} P(|T_n - g(\theta)| \leq \epsilon) = 1 \quad \forall \theta \in \Omega$$

ESTIMACIÓN DE PARÁMETROS

PARÁMETRO: ESTADÍSTICO ES UN NÚMERO QUE RESUME EL COMPORTAMIENTO DE UNA VARIABLE ALEATORIA Y QUE DESCRIBE PARCIAL O COMPLETAMENTE SU DISTRIBUCIÓN DE PROBABILIDAD. (μ, σ, σ^2, p) p : PROPORCIÓN (POBLACIÓN)


ESTADÍSTICO: ES UNA FUNCIÓN DE LAS VARIABLES ALEATORIAS QUE SE PUEDE OBSERVAR EN UNA MUESTRA Y QUE NO DEPENDE DE PARÁMETROS DESCONOCIDOS. TAMBÉN SE LLAMA ESTADÍSTICA O ESTADIGRAFO ($\bar{x}, S_{n-1}, S_{n-1}^2, \hat{p}$) (MUESTRA).

VARIABLES ALEATORIAS: FORMAN UNA MUESTRA ALEATORIA DE TAMAÑO n , SI SON INDEPENDIENTES Y TIENEN LA MISMA DISTRIBUCIÓN DE PROBABILIDAD.


MÉTODOS PARA ESTIMAR PARÁMETROS

- ▲ LA ESTIMACIÓN PUNTUAL DE UN PARÁMETRO RELATIVO A UNA POBLACIÓN ES EL VALOR NUMÉRICO DE UN ESTADÍSTICO CORRESPONDIENTE A ESE PARÁMETRO.
 $\hat{\mu} = 20.5$
- ▲ LA ESTIMACIÓN POR INTERVALOS ALEATORIOS. UN INTERVALO ALEATORIO ES UN INTERVALO EN DONDE AL MENOS UNO DE SUS LÍMITES ES UNA V.A.
 $\mu = (29.5, 21.5)$
- ▲ UNA HIPÓTESIS ES UNA AFIRMACIÓN ACERCA DE LA DISTRIBUCIÓN DE PROBABILIDAD DE UNA V.A.
 $H_0: \mu = 20.5$
 $H_1: \mu \neq 20.5$

INSEGURIDAD: CUANDO SE OBTIENE UNA ESTIMACIÓN PUNTUAL DE UN PARÁMETRO CUALQUIERA, ES DESEABLE QUE LA DISTRIBUCIÓN DE DICHA ESTIMACIÓN SE CENTRE EN EL PARÁMETRO REAL (AL CUAL SE LE LLAMA PARÁMETRO OBJETIVO), SI SE CUMPLE LA CONDICIÓN ANTERIOR ENTONCES EL ESTIMADOR SE LLAMA INSEGURADO.



$E(\hat{\theta}) = \theta$
ESTIMADOR
INSEGURADO.



$E(\hat{\theta}) > \theta$
ESTIMADOR
SESGADO.

SEA $\hat{\theta}$ UN ESTIMADOR PUNTUAL DEL PARÁMETRO θ . ENTonces SI $E(\hat{\theta}) = \theta$ SE DICE QUE $\hat{\theta}$ ES UN ESTIMADOR INSEGURADO DE θ , DE LO CONTRARIO SE DICE QUE ES SESGADO.

MÉTODO DE MOMENTOS

CECAYA

COSTEADA EN MÁRITOS

DEFINICIÓN: SEA X UNA VA. Y SEA $k \geq 1$ UN NÚMERO ENTERO. EL k -ESIMO MOMENTO DE X , SI EXISTE, ES EL NÚMERO $E(X^k)$.

A LOS NÚMEROS $E(X^1), E(X^2), \dots$ SE LES LLAMA TAMBién MOMENTOS POBLACIONALES.

SEA X_1, \dots, X_n UNA MA. DE LA DISTRIBUCIÓN $f(x; \theta)$.

DEFINICIÓN: SEA X_1, \dots, X_n UNA MA. Y SEA $k \geq 1$ UN ENTERO. EL k -ESIMO MOMENTO NUESTRAL ES LA VA.

$$\frac{1}{n} \sum_{i=1}^n X_i^k$$

ESTE MÉTODO CONSISTE EN IGUALAR LOS MOMENTOS POBLACIONALES CON LOS CORRESPONDIENTES MOMENTOS NUESTRALES Y RESOLVER ESTA ECUACIÓN (O SIST. DE ECUACIONES) PARA EL PARÁMETRO O VECTOR DE PARÁMETROS.

$$1^{\text{er}} \text{ MOMENTO POBLACIONAL: } E(X) = \frac{1}{n} \sum_{i=1}^n X_i$$

$$2^{\text{do}} \text{ MOMENTO POBLACIONAL: } E(X^2) = \frac{1}{n} \sum_{i=1}^n X_i^2$$

EXAMPLE:

SEA X UNA VA. CON FUNCIÓN DE DENSIDAD EN DONDE $\theta > 0$

$$f(x, \theta) = \begin{cases} \theta \cdot x^{\theta-1} & \text{SI } \theta < x < 1 \\ 0 & \text{E.O.C.} \end{cases}$$

⇒

$$E(X) = \frac{\theta}{1+\theta} \quad \text{SI } X_1, \dots, X_n \text{ ES UNA MA. DE ESTA DISTRIBUCIÓN.}$$

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

1º MOMENTO NUESTRAL ENTONCES POR EL MÉTODO DE MOMENTOS:

$$\frac{\hat{\theta}}{1+\hat{\theta}} = \bar{X} \Rightarrow \hat{\theta} = \bar{X} / (1-\bar{X})$$

∴ ES EL ESTIMADOR PARA θ

MÉTODO DE MÁXIMA VEROSIMILITUD

SEA (x_1, \dots, x_n) UN VECTOR ALEATORIO CUYA DISTRIBUCIÓN DEPENDE DE PARÁMETRO θ

DEFINICIÓN:

LA FUNCIÓN DE VEROSIMILITUD DEL VECTOR (x_1, \dots, x_n) ES $L(\theta) = f_{x_1, \dots, x_n}(x_1, \dots, x_n; \theta)$

LA LETRA "L" VIENE DE LIKELIHOOD QUE SE PUEDE TRADUCIR COMO VEROSIMILITUD
SI x_1, \dots, x_n SON INDEPENDIENTES

$$L(\theta) = f_{x_1}(x_1; \theta) \dots f_{x_n}(x_n; \theta)$$

Y CUANDO SON IDENTICAMENTE DISTRIBUIDAS.

$$L(\theta) = f(x_1; \theta) \dots f(x_n; \theta)$$

ESTO ES EL CASO DE UNA NUESTRA ALEATORIA. CONSISTE EN OBTENER EL VALOR DE θ QUE MAXIMIZA LA FUNCIÓN DE VEROSIMILITUD

$L(\theta) = f(x_1; \theta) \dots f(x_n; \theta)$. AL VALOR θ EN DONDE $L(\theta)$ ALCANZA SU MÁXIMO SE LA LLAMA ESTIMACIÓN DE MÁXIMA VEROSIMILITUD O ESTIMACIÓN MÁXIMA VEROSIMIL.

BÁSICAMENTE LA IDEA ES QUE θ DEBE SER TAL QUE EL VALOR NÚMERO OBSERVADO (x_1, \dots, x_n) DE LA MA. TENGA LA MÁXIMA PROBABILIDAD

EJEMPLO:

SEA x_1, \dots, x_n UNA MA. DE LA DISTRIBUCIÓN EXP(θ)

LA FUNCIÓN DE VEROSIMILITUD ES

$$\begin{aligned} L(\theta) &= f(x_1; \theta) \dots f(x_n; \theta) \\ &= \theta^{-n} e^{-\theta x_1} \dots \theta^{-n} e^{-\theta x_n} \\ &= \theta^{-n} e^{-\theta \bar{x}} \end{aligned}$$

$L(\theta)$ ES MÁXIMA EN EL MISMO PUNTO EN DONDE $\ln(L(\theta))$ LO ES.
 \Rightarrow

$$\ln(L(\theta)) = n \cdot \ln(\theta) - \theta \bar{x}$$

$$\therefore \frac{d}{d\theta} \ln(L(\theta)) = \frac{n}{\theta} - \bar{x}$$

$$\Rightarrow \theta = \bar{x} \quad \text{ADENAS ES UN MÁXIMO DADO QUE } \frac{d^2}{d\theta^2} \ln(L(\theta)) = -\frac{n}{\theta^2} < 0$$

$\hat{\theta} = \bar{x}$ ES LA ESTIMACIÓN PARA θ \rightarrow NÚMERO

$\hat{\theta} = \bar{x}$ ES EL ESTIMADOR PARA θ \rightarrow ESTADÍSTICA.

CECLAYA

INTERVALOS DE CONFIANZA PARA EL PARÁMETRO MEDIA EN UNA POBLACIÓN NORMAL. $N(\mu, \sigma^2)$

CASO 1: IC. PARA LA MEDIA DE UNA POBLACIÓN NORMAL CUANDO SE CONOCEN LA VARIANZA POBLACIONAL σ^2

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad \bar{X} \sim N\left(\mu_X, \frac{\sigma^2}{n}\right) \quad \bar{X} \sim N\left(\mu_X, \frac{\sigma^2}{n}\right) \quad Z \sim N(0, 1)$$

$$Z = \frac{\bar{X} - \mu_X}{\frac{\sigma}{\sqrt{n}}} \quad P\left(-\frac{z_{\alpha/2}}{2} \leq \frac{\bar{X} - \mu_X}{\frac{\sigma}{\sqrt{n}}} \leq \frac{z_{\alpha/2}}{2}\right) = 1 - \alpha$$

$$P(L_1 \leq \mu_X \leq L_2) = 1 - \alpha \quad P\left(\bar{X} - \frac{z_{\alpha/2}}{2} \frac{\sigma}{\sqrt{n}} \leq \mu_X \leq \bar{X} + \frac{z_{\alpha/2}}{2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

$$P\left(-\frac{z_{\alpha/2}}{2} \leq Z \leq \frac{z_{\alpha/2}}{2}\right) = 1 - \alpha$$

$$\boxed{\bar{X} - \frac{z_{\alpha/2}}{2} \frac{\sigma}{\sqrt{n}} \leq \mu_X \leq \bar{X} + \frac{z_{\alpha/2}}{2} \frac{\sigma}{\sqrt{n}}}$$

NOTAS:

ESTA FÓRMULA TAMBÉN SE UTILIZA CUANDO SE DESCONOCEN LA VARIANZA, PERO EL TAMAÑO DE LA MUESTRA $n > 30$

EJEMPLO:

CONSTRUIR UN INTERVALO DEL 95% DE CONFIANZA PARA LA MEDIA DE UNA POBLACIÓN NORMAL CON VARIANZA 4, Y $n=10$. ADÉNDS, UTILIZANDO LOS DATOS: 4, 7, 5, 10, 23, 17, 9, 15, 7 y 10 OBTENER UNA ESTIMACIÓN.

$$\bar{X} - \frac{z_{\alpha/2}}{2} \frac{\sigma}{\sqrt{n}} \leq \mu_X \leq \bar{X} + \frac{z_{\alpha/2}}{2} \frac{\sigma}{\sqrt{n}}$$

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{10} (4+7+5+10+23+17+9+15+7+10) \quad \bar{X} = 10.7$$

$$\sigma_X = \sqrt{\sigma^2} = 2 \quad n = 10 \quad 1 - \alpha = 0.95$$

$$P(Z \geq z_{\alpha/2}) = \frac{\alpha}{2} = 0.025$$

$$10.7 - 1.96 \left(\frac{2}{\sqrt{10}} \right) \leq \mu_X \leq 10.7 + 1.96 \left(\frac{2}{\sqrt{10}} \right) \Rightarrow 9.46 \leq \mu_X \leq 11.9$$

Norma

$s_n = \text{ESTÁNDAR}$

$s_{n-1} = \text{INESTÁNDAR}$

- EN UNA ESCUELA DE INGENIERIA, SE SELECCIONARON **50** ALUMNOS Y SE DETERMINO EL PROMEDIO DE HORAS QUE ESTUDIARON A LA SEMANA, EL CUAL FUE DE 3.5 h CON UNA DESVIACIÓN ESTÁNDAR DE LOS DATOS IGUAL A $s_n = \sqrt{3.92} \text{ h}$. CON ESTOS DATOS, ESTIMAR LAS HORAS QUE ESTUDIARON EN PROMEDIO LOS ALUMNOS CON UN COEFICIENTE DE CONFIDENCIA IGUAL A 95% .

$$n = 50 \quad \bar{x} = 3.5 \quad s_n = \sqrt{3.92}$$

$$\bar{x} - \frac{z_{\alpha/2}}{2} \frac{s_{n-1}}{\sqrt{n}} \leq \mu_x \leq \bar{x} + \frac{z_{\alpha/2}}{2} \frac{s_{n-1}}{\sqrt{n}}$$

n > 30
SOLO NÚMEROS GRANDES.

RECORDANDO

$$s_n = \frac{n-1}{n} s^2 \quad s_{n-1} = \frac{n-1}{n-1} s^2 \Rightarrow \text{PARA PASAR DE } s_n \text{ A } s_{n-1}$$

$$\Rightarrow s_{n-1} = \frac{n}{n-1} s_n = \frac{50}{49} (\sqrt{3.92}) = 2.02 \quad \rightarrow \text{DESVIACIÓN}$$

$$3.5 - 1.96 \frac{2}{\sqrt{50}} \leq \mu \leq 3.5 + 1.96 \frac{2}{\sqrt{50}}$$

ERRORES

$$2.9456 \leq \mu \leq 4.05$$

LONGITUD DEL INTERVALO
= 2 VECES EL ERROR
(OLGRADA)

X 7895 3763 024974136 6334029 98282 24491700 0000

CECAYA

CASO 2: I.C. PARA LA MEDIA DE 1 POBLACIÓN NORMAL CUANDO SE DESCONOCEN LA VARIANZA POBLACIONAL 6

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i \quad \bar{X} \sim N\left(\mu_x, \frac{\sigma_x^2}{n}\right) \quad \bar{X} \sim N\left(\mu_x, \frac{\sigma_x^2}{n}\right)$$

$$Z \sim N(0,1) \quad T = \frac{\bar{X} - \mu}{\frac{s_n}{\sqrt{n}}}$$

$$\Rightarrow \bar{X} - t_{\frac{\alpha}{2}, (n-1)} \frac{s_n}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{\frac{\alpha}{2}, (n-1)} \frac{s_n}{\sqrt{n}}$$

$$P(T \geq t_{\frac{\alpha}{2}, (n-1)}) = \frac{\alpha}{2}$$

NOTA: ESTA FÓRMULA SE UTILIZA SIEMPRE QUE SE DESCONOCE LA VARIANZA POBLACIONAL, PERO A PARTIR DE QUE EL TAMAÑO DE LA MUESTRA $n \geq 30$ CONVERGE CON LA FÓRMULA DE LA DISTRIBUCIÓN NORMAL ESTÁNDAR.

EJEMPLO

DIEZ EJES DE PRECISIÓN SON FABRICADOS EN UN LARGO PROCESO TIENEN UN DIÁMETRO PROMEDIO DE 0.908 CM, CON UNA DESVIACIÓN ESTÁNDAR DE 0.004 CM. CONSIDERANDO QUE LOS DATOS PROVIVEN DE UNA MUESTRA ALEATORIA CON DISTRIBUCIÓN NORMAL, CONSTRUIR UN INTERVALO DE CONFIANZA DEL 95% PARA EL DIÁMETRO PROMEDIO REAL DE LOS EJES FABRICADOS.

$$n=10 \quad \bar{x}=0.908 \quad s_n=0.004 \quad 1-\alpha=0.95 \quad t_{\frac{\alpha}{2}, (9)}=2.262$$

$$\alpha=0.05$$

$$\alpha=0.025$$

$$0.908 - 2.262 \frac{(0.004)}{\sqrt{10}} \leq \mu \leq 0.908 + 2.262 \frac{(0.004)}{\sqrt{10}}$$

$$0.905 \leq \mu \leq 0.911$$

PARA CONFIRMAR, SACAR PROMEDIO DE INTERVALO Y ESTE SERÁ \bar{x}

DETERMINACIÓN DEL TAMAÑO DE LA MUESTRA.

UNA DE LAS INTERROGANTES MÁS COMUNES ES LA DETERMINACIÓN DEL TAMAÑO DE LA MUESTRA CUANDO SE VA A HACER UN MUESTREO, PARA LA ESTIMACIÓN DE UN PARÁMETRO. PARA DETERMINAR EL TAMAÑO DE LA MUESTRA SE UTILIZAN LOS CONCEPTOS DE LA ESTIMACIÓN POR INTERVALOS, EN DONDE SE ACEPTA UN "ERROR" SOBRE LA ESTIMACIÓN PUNTUAL, POR EJEMPLO PARA LA MEDIA SE TIENE EL INTERVALO:

EN DONDE EL ERROR ES

$$\bar{X} - \frac{z_{\alpha/2} \sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + \frac{z_{\alpha/2} \sigma}{\sqrt{n}}$$

$$E = \frac{z_{\alpha/2} \sigma}{\sqrt{n}}$$

QUE SE SUMA Y SE RESTA AL ESTIMADOR PUNTUAL PARA GENERAR EL INTERVALO DE CONFIANZA. AL FIJAR UN VALOR PARA EL ERROR, Y CONOCIENDO O APROXIMANDO LA DESVIACIÓN ESTÁNDAR, SE PUEDE DESPEJAR EL TAMAÑO DE LA MUESTRA.

$$n = \left(\frac{z_{\alpha/2} \sigma}{E} \right)^2$$

EL REDONDEO SE HACE SIEMPRE HACIA ARRIBA, PARA ASEGURAR EL NIVEL DE SIGNIFICANCIA.

CASO 1 IC. PARA LA DIFERENCIA DE MEDIAS CUANDO SE CONOCEN LAS VARIANZAS POBLACIONALES σ_1^2, σ_2^2 (2 POBLACIONES).

CUANDO LA MUESTRA ES GRANDE EL ESTADÍSTICO PARA LA DIFERENCIA DE MEDIAS ESTÁ DADO POR

$$Z = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$


PODÉ LO QUE EL INTERVALO DE CONFIANZA DE LOS LADOS PARA LA DIFERENCIA DE MEDIAS CON UN NIVEL DE CONFIANZA $(1-\alpha) = 100\%$ CENTRADO EN $\mu_1 - \mu_2$ ES.

$$\bar{X}_1 - \bar{X}_2 - \frac{z_{\alpha/2}}{2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \leq \mu_1 - \mu_2 \leq \bar{X}_1 - \bar{X}_2 + \frac{z_{\alpha/2}}{2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$$

SIEMPRE ES $\bar{X}_1 - \bar{X}_2$ O RESPECTAR EL ORDEN.

DONDE $\frac{z_{\alpha/2}}{2}$ SE OBTIENE DE TABLAS CON DISTRIBUCIÓN NORMAL ESTÁNDAR DE FCRMA $\frac{\alpha}{2}$ Q.G.

$$P(Z \geq z) = \frac{\alpha}{2}$$



Norma

CECAYA

ESTIMACION DE LA DIFERENCIA DE LAS MEDIDAS

NOTA: SI SE DESCONOCEN LAS VARIANZAS DE LAS POBLACIONES σ_1^2 Y σ_2^2 Y LA MUESTRA ES GRANDE $n \geq 30$ ENTONCES SE PUEDE SUSTITUIR POR LOS ESTIMADORES PUNTUALES $S_{n_1-1}^2$ Y $S_{n_2-1}^2$.

EJEMPLO

LA RESISTENCIA DEL CAUCHO A LA ABRASION AUMENTA SI SE AGREGA UNA CARGA LIBRE DE SILICE Y UN AGENTE DE ACOPLAMIENTO PARA ENLAZAR QUÍMICAMENTE LA CARGA CON LAS CADENAS DE POLÍMERO DE CAUCHO CON SU AGENTE DE ACOPLAMIENTO TIPO I PIERON UNA RESISTENCIA PROMEDIO DE 92 Y LA VARIANZA DE LAS MEDIDAS FUE DE 20. CUARENTA MUESTRAS DE CAUCHO CON EL AGENTE DE ACOPLAMIENTO DEL TIPO II PIERON UN PROMEDIO DE 98 Y UNA VARIANZA DE 30 EN SUS MEDIDAS. ESTIMAR LA DIFERENCIA VERDADERA ENTRE LAS RESISTENCIAS PROMEDIO A LA ABRASIÓN EN UN INTERVALO DE CONFIANZA DEL 95%.

POBLACION I $n=50$

$$\bar{x}_1 = 92$$

$$S_{n-1}^2 = 20$$

POBLACION II $n=40$

$$\bar{x}_2 = 98$$

$$S_{n-1}^2 = 30$$

$$1-\alpha = 0.95$$

$$\alpha = 0.05$$

$$\frac{\alpha}{2} = 0.025$$

$$\bar{X}_1 - \bar{X}_2 - \frac{z\alpha}{2} \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}} \leq \mu_1 - \mu_2 \leq \bar{X}_1 - \bar{X}_2 + \frac{z\alpha}{2} \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}$$

$$92 - 98 - 1.96 \sqrt{\frac{20}{50} + \frac{30}{50}} \leq \mu_1 - \mu_2 \leq 92 - 98 + 1.96 \sqrt{\frac{20}{50} + \frac{30}{50}}$$

$$(-8.1019 \leq \mu_1 - \mu_2 \leq -3.8981)$$

Se concluye que los medios no son iguales y los signos negativos indican que μ_2 es MÁS GRANDE que μ_1 .

El INTERVALO OBTENIDO, $-8.1019 \leq \mu_1 - \mu_2 \leq -3.8981$, TIENE LA INTERPRETACIÓN ADICIONAL DE QUE, AL NO CONTENER EL 0 UNA DE LAS MEDIDAS ES MAYOR QUE LAS OTRAS, EN ESTE CASO EL INTERVALO INDICA QUE LA MEDIDA μ_2 ES MAYOR QUE LA MEDIDA μ_1 . POR LO QUE

$$\mu_2 > \mu_1$$

CASO 2 IC. PARA LA DIFERENCIA DE 2 POBLACIONES NORMALES CUANDO SE DESCONOCE LA VARIANZA POBLACIONAL σ_1^2 , σ_2^2 PERO SABE QUE SON IGUALES $\sigma_1^2 = \sigma_2^2$

CUANDO LAS MUESTRAS SON PEQUEÑAS Y PROVIENEN DE POBLACIONES NORMALES CON VARIANZA DESCONOCIDA PERO IGUALES, ENTONCES EL ESTADÍSTICO PARA LA DIFERENCIA ENTRE DOS MEDIAS ES UN TÉSTIGO:

$$T = \frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

DONDE S_p^2 = ESTIMADOR CONBINADO DE LA VARIANZA.

DONDE $S_p^2 = \frac{(n_1-1)(S_1^2) + (n_2-1)(S_2^2)}{n_1 + n_2 - 2}$ $T \sim t_{(n_1+n_2-2)}$

PODÉ LO QUE EL INTERVALO DE CONFIANZA DE DOS LADOS PARA LA DIFERENCIA DE MEDIAS, CON UN NIVEL DE CONFIANZA $(1-\alpha)$ 100%, CENTRADO EN $\mu_1 - \mu_2$ ES

$$\bar{X}_1 - \bar{X}_2 - t_{(n_1+n_2-2)} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \leq \mu_1 - \mu_2 \leq \bar{X}_1 - \bar{X}_2 + t_{(n_1+n_2-2)} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$$

EJEMPLO

PARA DOS MUESTRAS EXTRAÍDAS DE DISTRIBUCIONES NORMALES SE OBTUVIERON LOS SIG. RESULTADOS.

$$\begin{aligned} n_1 &= 9 & n_2 &= 7 \\ \bar{y}_1 &= 43,71 & \bar{y}_2 &= 39,63 \\ S_1 &= 5,88 & S_2 &= 7,68 \end{aligned}$$

OBTENER EL INTERVALO DE CONFIANZA PARA LA DIFERENCIA DE MEDIAS CON UN COEFICIENTE DE CONFIANZA IGUAL A 0,95. CONSIDERANDO $\sigma_1^2 = \sigma_2^2$

$$S_p^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1 + n_2 - 2} = \frac{(9-1)(5,88)^2 + (7-1)(7,68)^2}{9+7-2} = 45,035$$

$$S_p = \sqrt{S_p^2} = 6,71 \Rightarrow 43,71 - 39,63 \pm 2,145(6,71) \sqrt{\frac{1}{9} + \frac{1}{7}} \\ -3,17 \leq \mu_1 - \mu_2 \leq 11,33$$

$$t_{0.025, (14)} = 2,145$$

DE LOS CASOS ANTERIORES SE PUEDE ESTIMAR QUE

1. EL INTERVALO OBTENIDO $-3.19 \leq \mu_1 - \mu_2 \leq 311.33$, TIENE INTERPRETACIÓN ADICIONAL DE QUE, AL CONTENER EL CERO, SE PUEDE ESTIMAR QUE LAS MEDIAS POBLACIONALES SON IGUALES. EN ESTE CASO EL INTERVALO INDICA QUE LA MEDIA μ_1 ES IGUAL QUE LA MEDIA μ_2 POR LO QUE SE CONCLUE: $\mu_1 = \mu_2$

CASO 3 Si \bar{x}_1 y \bar{x}_2 SON LAS MEDIAS ARITMÉTICAS DE LA REALIZACIÓN DE DOS MUESTRAS ALEATORIAS INDEPENDIENTES DE TAMAÑOS n_1 Y n_2 , RESPECTIVAMENTE, DE POBLACIONES APROXIMADAMENTE NORMALES DE LAS QUE SE DESCONOCEN σ_1^2, σ_2^2 PERO SE SABE QUE $\sigma_1^2 \neq \sigma_2^2$ EL I.C. DE DOS LADOS PARA LA DIFERENCIA DE MEDIAS CON UN NIVEL DE CONFIANZA $(1-\alpha) 100\%$ CENTRADO EN $\mu_1 - \mu_2$ ES:

$$\bar{x}_1 - \bar{x}_2 - t_{(\alpha/2, v)} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}} \leq \mu_1 - \mu_2 \leq \bar{x}_1 - \bar{x}_2 + t_{(\alpha/2, v)} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

$$v = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2} \right)}{\left(\frac{s_1^2}{n_1} \right)^2 \left(\frac{1}{n_1-1} \right) + \left(\frac{s_2^2}{n_2} \right)^2 \left(\frac{1}{n_2-1} \right)}$$

NOTA: EN LA FÓRMULA DE GRADOS DE LIBERTAD, SE DEBE REDONDEAR AL ENTERO MÁS PRÓXIMO. POR EJEMPLO $14.5 = 5, 14.3 = 14$

EJEMPLO

PARA DOS MUESTRAS EXTRAÍDAS DE DISTRIBUCIONES NORMALES SE OBTUVIERON LOS SIGUIENTES RESULTADOS.

$$\begin{aligned} n_1 &= 9 & n_2 &= 7 \\ \bar{x}_1 &= 43,71 & \bar{x}_2 &= 39,63 \\ s_1 &= 5,88 & s_2 &= 7,68 \end{aligned}$$

OBTENER EL INTERVALO DE CONFIANZA PARA LA DIFERENCIA DE MEDIAS CON UN COEFICIENTE DE CONFIANZA IGUAL A 0.95 CONSIDERANDO $\sigma_1^2 \neq \sigma_2^2$

$$1 - \alpha = 0,95 \quad \frac{\alpha}{2} = 0,025$$

$$v = 11$$

... ERROR ...

$$t_{(0.025, 11)} = 2.201 \quad 43,71 - 39,63 \pm 2,201 \sqrt{\frac{5,88^2}{9} + \frac{7,68^2}{7}}$$

$$-3,629 \leq \mu_1 - \mu_2 \leq 11,789$$

EL INTERVALO OBTENIDO, $-3.62 \leq M_1 - M_2 \leq 11.78$, TIENE UNA INTERPRETACIÓN ADICIONAL DE QUE, AL CONTENER AL CERO, SE PUEDE ESTIMAR QUE LAS MEDIAS POBLACIONALES SON IGUALES. EN ESTE CASO EL INTERVALO INDICA QUE LA MEDIA M_1 ES IGUAL QUE LA MEDIA M_2 POR LO QUE CONCLUYE LO SIGUIENTE

$$M_1 = M_2$$

SI X ES UNA VARIABLE ALEATORIA CON MEDIA M_x Y VARIANZA σ_x^2 ENTONCES EL ESTADÍSTICO ENCUENTRADO ES

$$\frac{(n-1)S_n^2}{\chi_{\frac{\alpha}{2},(n-1)}^2} \leq \sigma^2 \leq \frac{(n-1)S_n^2}{\chi_{1-\frac{\alpha}{2},(n-1)}^2}$$

$$X_2 = \frac{n-1}{\sigma^2} S_n^2, \quad \chi^2 \sim \chi^2(n-1)$$

PARA CREAR UN INTERVALO DE CONTIENCIA PARA UNA PROPORCIÓN SE HACE EL USO DE LA DISTRIBUCIÓN NORMAL ESTIMAR Y APROXIMAR.

$$\hat{p} - \frac{z\alpha}{2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \leq p \leq \hat{p} + \frac{z\alpha}{2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

MIENTRAS QUE PARA LA DIFERENCIA DE PROPORCIONES.

$$(\hat{p}_1 - \hat{p}_2) \pm \frac{z\alpha}{2} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$$

DIFERENCIA DE PROPORTIONES CON BASE A

CECRA Y A

EJEMPLO

CALCULE LOS SIGUIENTES DATOS

8.2 8.28 8.24 8.23 8.21 8.25 8.24 8.23
8.29 8.25 8.2 8.26 8.19 8.23 8.26

a) Obtener

UN INTERVALO DE CONFIANZA DE DOS CADEROS DEL 95% PARA s_x^2

b) UN INTERVALO DE CONFIANZA INFERIOR DEL 95% PARA s_x^2

c) UN INTERVALO DE CONFIANZA SUPERIOR DEL 95% PARA s_x^2

a)  DE DONDE B DONDE ENTRA LA POBLACION

b)  (SIX FIGAS SUPERMAN ALTURA)


c)  (HO DONAIS Y JUEGOS INFANTILES)

$$\bar{x} = 8.23 \quad S_{n-1} = 0.0253$$

a)

USANDO

$$\frac{(n-1)S_{n-1}^2}{\chi_{\frac{\alpha}{2}, (n-1)}^2} \leq s_x^2 \leq \frac{(n-1)S_{n-1}^2}{\chi_{1-\frac{\alpha}{2}, (n-1)}^2}$$



$$\frac{\alpha}{2} = 0.025 \quad 1 - \frac{\alpha}{2} = 0.975 \quad v = n-1 = 14$$

A MAYOR PROBABILIDAD
K SERA MAS PEQUEÑA

$$\frac{(14)(0.0253)^2}{26.1189} \leq s_x^2 \leq \frac{(14)(0.0253)^2}{5.63}$$

$$\chi_{0.025, 14}^2 = 5.63$$

$$0.0003438 \leq s_x^2 \leq 0.0015916$$

$$\chi_{0.025, 14}^2 = 26.12$$

$$0.01854 \leq s_x = 0.039$$

b)

$$\alpha = 0.05$$


$$V = 14$$

$$\chi^2_{0.05, 14} = 23.68$$

$$\frac{(n-1)S_n^2}{\chi^2_{\alpha, n-1}} \leq c_x^2$$

$$\frac{(14)(0.0253)^2}{23.68} \leq c_x^2$$

$$0.0003784 \leq c_x^2$$




c) $1-\alpha = 0.95$ $V = 14$

$$c_x^2 \leq \frac{(n-1)S_n^2}{\chi^2_{1-\alpha, (n-1)}}$$

$$c_x^2 \leq \frac{(14)(0.0253)^2}{6.57}$$

$$c_x^2 \leq 0.0013639$$



$$\frac{1}{(1-\alpha)(n-1)} \cdot \frac{\chi^2_{1-\alpha, (n-1)}}{S_n^2} = \frac{\chi^2_{1-\alpha, (n-1)}}{S_n^2} + \frac{1}{(1-\alpha)(n-1)}$$

CECLAYA

INTERVALO DE CONFIANZA PARA LA RAZÓN DE VARIANZAS.


Si X y Y son $W.$ A.R. INDEPENDIENTES CON DISTRIBUCIONES NORMALES CON MEDIDAS μ_X y μ_Y DESCONOCIDAS Y VARIANZAS S_x^2 y S_y^2 DESCONOCIDAS, RESPECTIVAMENTE, ENTONCES EL ESTADÍSTICO EMPLEADO ES:

$$F = \frac{\frac{S_x^2}{S_y^2}}{\frac{S_y^2}{S_x^2}} \quad F \sim F(n_y - 1, n_x - 1)$$

DONDE

UTILIZANDO EL ESTADÍSTICO F SE OBTIENE EL INTERVALO DE CONFIANZA DE DOS CANTOS CON UN COEFICIENTE $(1-\alpha)100\%$ PARA LA PROPORCIÓN DE VARIANZAS. $\frac{S_x^2}{S_y^2}$ EL CUAL ES:

$$\frac{S_x^2}{S_y^2} F_{1-\frac{\alpha}{2}, (n_y - 1, n_x - 1)} \leq \frac{S_x^2}{S_y^2} \leq \frac{S_x^2}{S_y^2} F_{\frac{\alpha}{2}, (n_y - 1, n_x - 1)}$$



O BIEN UTILIZANDO EL RECÍPROCO:

$$\frac{S_x^2}{S_y^2} \frac{1}{F_{\frac{\alpha}{2}, (n_x - 1, n_y - 1)}} \leq \frac{S_x^2}{S_y^2} \leq \frac{S_x^2}{S_y^2} \frac{1}{F_{1-\frac{\alpha}{2}, (n_x - 1, n_y - 1)}}$$

$$\frac{\alpha}{2} = LO \ VEO \ A \ ENCONTRAR \ EN \ TABLAS$$

$$1 - \frac{\alpha}{2} = SERÁ \ DIFÍCIL \ ENCONTRAR$$

ANALISIS

ESTADISTICA DEL DIA ESTIMACION DE COVARIANZA

SE EXTRAEN DOS MUESTRAS INDEPENDIENTES DE POBLACIONES NORMALES OBTENIENDOSE LOS SIG. DATOS

$$n_1 = 15$$

$$\bar{x}_1 = 300$$

$$S_1^2 = 16$$

$$n_2 = 10$$

$$\bar{x}_2 = 325$$

$$S_2^2 = 49$$

CONSTRUIR UN INTERVALO DE CONFIDENCIA AL 95% DE RPTOS DEL 95% CON RESPECTO A LA RELACION DE LAS VARIANZAS $\frac{G_1^2}{G_2^2}$

$$\frac{S_1^2}{S_2^2} \cdot \frac{1}{f_{\alpha/2, (n_1-1, n_2-1)}} \leq \frac{G_1^2}{G_2^2} \leq \frac{S_1^2}{S_2^2} \cdot f_{\alpha/2, (n_1-1, n_2-1)}$$

$$\frac{1}{f_{0.025, (9, 14)}} = \frac{1}{3.8} = 0.263 \quad f_{0.0025, (9, 14)} = 3.209$$

$$\frac{16}{49} \cdot (0.263) \leq \frac{G_1^2}{G_2^2} \leq \frac{16}{49} \cdot (3.209)$$

$$0.085 \leq \frac{G_1^2}{G_2^2} \leq 1.048$$

1. EL INTERVALO OBTENIDO, $0.085 \leq \frac{G_1^2}{G_2^2} \leq 1.048$, TIENE LA INTERPRETACION ADICIONAL DE QUE, AL CONSIDERAR EL CASO SE PUEDE ESTIMAR QUE LAS VARIANZAS POBLACIONALES SON IGUALES. EN ESTE CASO EL INTERVALO INDICA QUE LA VARIANZA G_1^2 ES IGUAL A LA VARIANZA G_2^2 . POR LO QUE SE CONCLUYE LO SIGUIENTE:

$$G_1^2 = G_2^2$$

INTERVALO DE CONFIDENCIA
0.085 < $\frac{G_1^2}{G_2^2}$ < 1.048

AMPLIAR ESTA ESTIMACION CON UNA COLOCACION DE

CELAYA

INTERVALOS DE CONFIANZA PARA UNA PROPORCIÓN

SI SE TOME UNA MUESTRA DE TAMAÑO n DE UNA POBLACIÓN MUY GRANDE (O INFINITA), Y X OBSERVACIONES PERTENECEN A LA CLASE DE INTERES, ENTONCES $\hat{p} = \frac{x}{n}$ ES UN ESTIMADOR PUNTOUAL DE LA PROPORCIÓN DE LA POBLACIÓN QUE PERTENECE A LA CLASE EN CUESTIÓN, Y LA DISTRIBUCIÓN DE MEJSTREO ES:

$$\hat{p} = \frac{x}{n} \rightarrow \text{ÉXITO} \quad z = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \rightarrow \text{CASOS POSIBLES}$$

DONDE $z \sim N(0,1)$
NORMAL ESTÁNDAR.

Y n Y p SON LOS PARÁMETROS DE LA DISTRIBUCIÓN BINOMIAL

UTILIZANDO EL ESTADÍSTICO z Y APROXIMANDO LA CANTIDAD $p(1-p)$ MEDIANTE EL ESTIMADOR PUNTOUAL $\hat{p}(1-\hat{p})$ SE OBTIENE EL INTERVALO DE CONFIANZA DE DOS LADOS CON UN COEFICIENTE $(1-\alpha) 100\%$ PARA LA PROPORCIÓN p ES:

$$\hat{p} - z_{\frac{\alpha}{2}} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \leq p \leq \hat{p} + z_{\frac{\alpha}{2}} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

EJEMPLO

EN UNA MUESTRA AL AZAR DE 60 SECCIONES DE TUBO EN UNA FÁBRICA QUINCEA, 8 DE 600 MOSTRARON SEÑALES DE CORROSIÓN SERIA. CONSTRUIR UN INTERVALO DE CONFIANZA DEL 95% PARA LA PROPORCIÓN DE LOS TRAMOS DE TUBO CON CORROSIÓN SERIA.

$$\hat{p} = \frac{x}{n} = \frac{8}{60} \quad z_{\frac{\alpha}{2}} = z_{0.025} = 1.96$$

$$\frac{8}{60} - 1.96 \sqrt{\frac{\frac{8}{60}(1-\frac{8}{60})}{60}} \leq p \leq \frac{8}{60} + 1.96 \sqrt{\frac{\frac{8}{60}(1-\frac{8}{60})}{60}}$$

$$0.09731 \leq p \leq 0.21939$$

IMPORTANTE: $9.7\% \leq p \leq 21.93\%$

LA PROPORCIÓN NO PUEDE SER NEGATIVA

INTERVALO DE CONFIANZA PARA LA DIFERENCIA DE PROPORCIONES

SI DOS MUESTRAS INDEPENDIENTES DE TAMAÑO n_1 Y n_2 SE EXTRAEN DE POBLACIONES INFINITAS CON DISTRIBUCIÓN DE BERNOULLI, X REPRESENTA EL NÚMERO DE OBSERVACIONES DE LA PRIMERA MUESTRA QUE CORRESPONDE A LA CLASE DE INGRESOS, Y Y REPRESENTA EL NÚMERO DE OBSERVACIONES DE LA SEGUNDA MUESTRA QUE CORRESPONDE A LA CLASE EN CUESTIÓN, ENTonces LA DISTRIBUCIÓN DE MUESTREO PARA LA DIFERENCIA DE PROPORCIONES ESTÁ DADA POR:

$$z = \frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}}$$

DONDE:

$$z \sim N(0, 1)$$

DE LA FORMA ANTERIOR SE OBTIENE EL INTERVALO DE CONFIANZA DE LOS CASOS CON UN COEFICIENTE $(1-\alpha)100\%$. PARA LA DIFERENCIA DE PROPORCIONES $p_1 - p_2$ EL COFICIENTE:

$$(\hat{p}_1 - \hat{p}_2) - \frac{z_{\alpha/2}}{\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}} \leq p_1 - p_2 \leq (\hat{p}_1 - \hat{p}_2) + \frac{z_{\alpha/2}}{\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}}$$

— ERROR —————— | | — ERROR ——————

CECLAYA

EJEMPLO

dos grupos de 80 pacientes tomaron parte de un experimento en el cual un grupo recibió píldoras que contenían un antipirético, mientras que otro grupo se le sometió a un placebo, es decir, una píldora sin droga activa. En el grupo que recibió el medicamento 23 exhibieron síntomas dolorosos, mientras que en el otro grupo 41 los exhibieron. Obtener el intervalo de confianza al 99% para la diferencia de proporciones.

$$\hat{P}_1 = \frac{x}{n} = \frac{23}{80} \quad \hat{P}_2 = \frac{y}{m} = \frac{41}{80} \quad z_{\alpha/2} = z_{0.005} = 2.575$$

$$\left(\frac{23}{80} - \frac{41}{80} \right) \pm 2.575 \sqrt{\frac{\left(\frac{23}{80} \right) \left(1 - \frac{23}{80} \right)}{80} + \frac{\left(\frac{41}{80} \right) \left(1 - \frac{41}{80} \right)}{80}}$$

$$-0.4119 \leq P_1 - P_2 \leq -0.031$$

SON DIFERENTES Y P_2 ES MAYOR QUE P_1
POR NO CONTENER AL 0

OJO SI

ESTAR

DE UNA ZONA

ANOTACIÓN

HIPÓTESIS. ES UNA AFIRMACIÓN ACERCA DE LA DISTRIBUCIÓN DE PROBABILIDAD DE UNA V.A.

ERRORES DE TIPO I Y TIPO II

LAS PRUEBAS DE HIPÓTESIS SON PARTE DE LA INFERNENCIA ESTADÍSTICA Y A MENUDO INVOLUCRAN A MÁS DE UN PARÁMETRO DE LA DISTRIBUCIÓN.

SUPONGASE POR EJEMPLO QUE SE DESEA ESTIMAR EL PROMEDIO DE LA ESTIMACIÓN DE LOS ALUMNOS DE LA F.I., Y SE PRETENDE SABER SI EL PROMEDIO ES 1.67 O NO LO ES. LO ANTERIOR SE EXPRESARÍA:

LA HIPÓTESIS ES EL PARÁMETRO


$$H_0: \mu = 1.67 \text{ [m]} \quad \text{HIPÓTESIS NULA} \quad (\text{SIEMPRE VA EL IGUAL})$$

$$H_1: \mu \neq 1.67 \text{ [m]} \quad \text{HIPÓTESIS ALTERNATIVA}$$

CONTRASTES DE HIPÓTESIS

EXISTEN 4 TIPOS DE HIPÓTESIS, LOS CUALES SON:

01	02	03	04
$H_0: \theta \geq \theta_0$	$H_0: \theta \leq \theta_0$	$H_0: \theta = \theta_0$	$H_0: \theta \in (\theta_1, \theta_2)$
$H_1: \theta < \theta_0$	$H_1: \theta > \theta_0$	$H_1: \theta \neq \theta_0$	$H_1: \theta \notin (\theta_1, \theta_2)$



PRUEBA ALTERNATIVA
DE UN LADO.




PRUEBA ALTERNATIVA
DE DOS LADOS.

CELAYA

REGIONES DE ACEPTACIÓN O RECHAZO.

PARA PROBAR UNA HIPÓTESIS ES NECESARIO SELECCIONAR UNA MUESTRA ALÉATORIA, Y MEDIANTE UN ESTADÍSTICO DE PRUEBA ADECUADO DETERMINAR SI SE ACEPTA LA HIPÓTESIS H_0 O SE RECHAZA, ACEPTANDOSE LA HIPÓTESIS ALTERNATIVA H_1 . CON LA FINALIDAD DE RECHAZAR O RECHAZAR UNA HIPÓTESIS, DEBEN CONGRUÍRSE REGIONES DE ACEPTACIÓN Y RECHAZO, POR EJEMPLO, POR EJEMPLO PARA LA HIPÓTESIS SOBRE LA MEDIA POBLACIONAL PLANTEADA ANTERIORMENTE SE TIENE.



UNA PRUEBA DE HIPÓTESIS PARA ALGUNA CARACTÉRISTICA DESCONOCIDA DE UNA POBLACIÓN ES CUALQUIER REGLA QUE PERMITE RECHAZAR O NO RECHAZAR UNA HIPÓTESIS NULA CON BASE A UNA MUESTRA ALÉATORIA DE LA POBLACIÓN.

$$\bar{z} = \frac{\bar{x}-\mu}{\frac{\sigma}{\sqrt{n}}} \quad \bar{x} = \frac{1}{n} \sum x_i \quad \mu = \text{PROPOSICIÓN}$$

ERRORES DE TIPO I Y TIPO II

LA DECISIÓN QUE SE TOMA DE ACEPTAR O RECHAZAR UNA HIPÓTESIS SEGÚN LOS DATOS OBSERVADOS EN UNA MUESTRA Y EMPLEANDO UN ESTADÍSTICO DE PRUEBA ADECUADO, ESTE SOBRE PUEDE COMETRER. EN PARTICULAR SE PUEDE COMETER DOS TIPOS DE ERRORES,

- 1) CUANDO LA HIPÓTESIS NULA H_0 SE RECHAZA SIGNIFICANDO QUE ES VERDADERA SE COMETE UN ERROR DE TIPO I
- 2) MIENTRAS QUE SI SE ACEPTA LA HIPÓTESIS NULA H_0 CUANDO ES Falsa ENTONCES SE COMETE UN ERROR DEL TIPO II

TABLA 1 TIPOS DE ERROR EN LAS PRUEBAS DE HIPÓTESIS.

		ESTADO DE LA HIPÓTESIS	
SI LA HIPÓTESIS ES		H_0 ES VERDADERA	H_0 ES FALSA
DECISIÓN	Y LA CONCLUSIÓN ES		
	NO SE RECHAZA H_0	NINGUN ERROR	ERROR TIPO II
	SI SE RECHAZA H_0	ERROR TIPO I	NINGUN ERROR

LAS PROBABILIDADES DE COMETER ERRORES DEL TIPO I Y II SE DENOTAN MEDIANTE α Y β RESPECTIVAMENTE, ES DECIR.

$$P(\text{RECHAZAR } H_0 \mid H_0 \text{ ES VERDADERA}) = P(\text{ERROR TIPO I}) = \alpha$$

$$P(\text{ACEPTAR } H_0 \mid H_0 \text{ ES FALSA}) = P(\text{ERROR TIPO II}) = \beta$$

TABLA 2 . PROBABILIDAD DE ERRORES EN LAS PRUEBAS DE HIPÓTESIS.

SI LA HIPÓTESIS ES		H_0 ES VERDADERA	H_0 ES FALSA
Y LA CONCLUSIÓN ES			
NO SE RECHAZA H_0	SI SE RECHAZA H_0	$1 - \alpha$	β
		α	$1 - \beta$

LA POTENCIA DE UNA PRUEBA DE HIPÓTESIS ESTADÍSTICA ES LA PROBABILIDAD DE RECHIPIZAR UNA HIPÓTESIS FALSA, ES DECIR

$$\text{POTENCIA DE UNA PRUEBA} = P(\text{RECHAZAR } H_0 \mid H_0 \text{ FALSA})$$

CELAYA

PRUEBAS DE HIPÓTESIS

ADEMÁS DE LAS PRUEBAS DE HIPÓTESIS UNILATERALES Y BILATERALES COMO SEÑORÓ LAS PRIMERAS ECUACIONES, LAS PRUEBAS SE CLASIFICAN EN SIMPLES Y COMPLEJAS.

LAS HIPÓTESIS SIMPLES SON AQUELLAS QUE ESPECIFICAN EL VALOR DEL PARÁMETRO θ O C QUE SE REFIEREN, POR EJEMPLO:

$$H_0: p = \frac{1}{2} \rightarrow \text{PROPORCIÓN}$$

LAS HIPÓTESIS COMPLEJAS SON AQUELLAS QUE NO ESPECIFICAN EL VALOR DEL PARÁMETRO, POR EJEMPLO:

$$H_0: p > \frac{1}{2} \quad H_1: p \neq \frac{1}{2}$$

EJERCICIO

EL TIEMPO TRANSCURRIDO X ENTRE DOS SEÑALES CONSECUTIVAS DE UN CONTADOR Geiger DE PARCÍCULAS RADIACTIVAS, ES UNA V.A. CON DISTRIBUCIÓN EXPONENCIAL CON PARÁMETRO λ

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x} & x > 0 \\ 0 & \text{etc.} \end{cases}$$

A FIN DE PROBAR LA HIPÓTESIS H_0 DE QUE PARA UN MATERIAL EN PARTICULAR $\lambda = 2$, CONTRA LA ALTERNATIVA H_1 , DE $\lambda = 1$, SE REALIZA UNA SOLA OBSERVACIÓN DE X Y SE DECIDE NO RECHAZAR H_0 SI EL VALOR OBSERVADO DE X OCURRE EN EL INTERVALO $(0, 1)$. CALCULAR LOS TAMAÑOS DE LOS ERRORES TIPO I Y II,

$$H_0: \lambda = 2 \quad \text{PARA NO RECHAZAR TIENE } (0, 1)$$

$$H_1: \lambda = 1$$

PARA TIPO I

$$\alpha = P(X > 1 | \lambda = 2) = \int_1^{\infty} 2e^{-2x} dx = e^{-2} \Rightarrow \alpha = e^{-2} \approx 0.135$$

PARA TIPO II

$$\beta = P(0 \leq X \leq 1 | \lambda = 1) = \int_0^1 e^{-x} dx = 1 - e^{-1} \quad \beta = 1 - e^{-1} \approx 0.632$$

PRUEBAS DE HIPÓTESIS PARA EL ESTIMADOR DE LA MEDIDA

CASO 1

$$\begin{matrix} \mu \\ 6 \end{matrix}$$

DIST
Z

H₀ PARA LA MEDIA DE 1 POBLACIÓN NORMAL CUANDO SE CONOCÉ LA VARIANZA POBLACIONAL σ^2

$$Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

CASO 2

$$\begin{matrix} \mu \\ 6 \end{matrix}$$

H₀, PARA LA MEDIA DE 1 POBLACIÓN NORMAL CUANDO SE DESCONOCE LA VARIANZA POBLACIONAL σ^2

$$T = \frac{\bar{X} - \mu}{\frac{s_{n-1}}{\sqrt{n}}}$$

DISTRIBUCIÓN T

CASO 1 H₀ PARA LA MEDIA DE 1 POBLACIÓN NORMAL CUANDO SE CONOCÉ LA VARIANZA POBLACIONAL σ^2

CUANDO SE DESEA REALIZAR UNA HIPÓTESIS CON RESPECTO A LA MEDIDA DE UNA VARIABLE ALEATORIA X, DEBE SER PONER CON DISTRIBUCIÓN NORMAL YA SEA PORQUE X SE DISTRIBUYE NORMALMENTE O POR EL TEOREMA DEL LIMITE CENTRAL. SI SE CONSIDERA QUE LA MEDIA μ SE DESCONOCE PERO SE CONOCÉ LA VARIANZA σ^2 , ENTONCES LA HIPÓTESIS BILATERAL PUEDEN FORMULARSE COMO:

$$H_0: \mu = \mu_0$$

$$H_1: \mu \neq \mu_0$$

DONDE μ_0 ES UNA CONSTANTE ESPECÍFICA, Y EL ESTADÍSTICO DE PRUEBA ES

$$Z = \frac{\bar{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$$

DONDE $Z \sim N(0, 1)$

Norma

DECAYA

GEMICO

CONSIDERENSE UNA POBLACIÓN CON DISTRIBUCIÓN NORMAL CON PARÁMETROS μ DESCONOCIDO Y $\sigma^2 = 4$. CON BASE EN UNA MUESTRA DE 30 OBSERVACIONES EN LA CUADE $\bar{x} = 10$ Y $s^2 = 3,5$, DETERMINAR SI ES CORRECTO SUPONER QUE $\mu = 12$ CON UN NIVEL DE SIGNIFICANCIA DE 0.01.

LA PRUEBA DE HIPÓTESIS ESTADÍSTICA ES:

$$H_0: \mu = 12 \quad \text{X}$$


$$H_1: \mu \neq 12 \quad \checkmark$$

EL ESTADÍSTICO DE PRUEBA ES \rightarrow ESTANDARIZANDO

$$\bar{x} \sim N(\mu, \frac{\sigma^2}{n})$$

$$z_0 = \frac{\bar{x} - \mu_0}{\sqrt{\frac{\sigma^2}{n}}} \sim N(0, 1)$$

Y LAS REGIONES CRÍTICAS DE ACEPTACIÓN



Y ENCUENTRANDO EL ESTADÍSTICO DE PRUEBA PARA LA MUESTRA DADA Y SUPONIENDO CIERTA H_0 SE TIENE.

$$z_0 = \frac{\bar{x} - \mu_0}{\sqrt{\frac{\sigma^2}{n}}} = \frac{10 - 12}{\sqrt{\frac{4}{30}}} = -5.47 \quad \text{X}$$

DE DONDE SE OBSERVA QUE EL ESTADÍSTICO SE ENCUENTRA FUERA DE LA REGIÓN DE ACEPTACIÓN $-2.575 < z_0 < 2.575$ ($z_0 < -2$)
 \therefore SE CONCLUYE QUE, CON BASE EN ESTA MUESTRA, NO ES ADECUADO SUPONER $\mu = 12$ POR LO QUE H_0 SE RECHAZA X

Norma

CASO 2 P.H. PARA LA MEDIA DE UNA POBLACIÓN NORMAL CUANDO SE DESCONOCE LA VARIANZA POBLACIONAL σ^2

CUANDO EN LA PRÁCTICA NO SE CONOCÉ LA VARIANZA POBLACIONAL σ^2 , PUEDE SUSTITUIRSE SU VALOR POR s_n^2 , SI LA MUESTRA ES GRANDE ($n \geq 30$) SIN TENER UN EFECTO PERJUDICIAL DE CONSIDERACIÓN. SI LA VARIANZA SE DESCONOCE Y LA MUESTRA ES PEQUEÑA ($n < 30$) ENTONCES EL ESTADÍSTICO DE PRUEBA ES:

$n \geq 30 \quad \text{G}^2 \text{ DESCONOCIDA.}$

$n < 30 \quad \text{G}^2 \text{ DESCONOCIDA}$

$$Z = \frac{\bar{X} - \mu_0}{\frac{s}{\sqrt{n}}}$$

$$T_0 = \frac{\bar{X} - \mu_0}{\frac{s}{\sqrt{n}}}$$

SIEMPRE QUE LA POBLACIÓN TENGÁ DIST. NORMAL.

PRUEBAS DE HIPÓTESIS SOBRE LA IGUALDAD DE DOS MEJAS

CASO 1

$$\mu_1 = \mu_2$$

P.H. SOBRE LA IGUALDAD DE MEDIAS DE 2 POBLACIONES

$$\sigma_1^2, \sigma_2^2$$

NORMALES CUANDO SE CONOCEN LAS VARIANZAS POBLACIONALES σ_1^2, σ_2^2

Z_0 (MUESTRA GRANDE)

CASO 2

$$\mu_1 = \mu_2$$

P.H. SOBRE LA IGUALDAD DE MEDIAS DE 2 POBLACIONES

$$\sigma_1^2 = \sigma_2^2$$

NORMALES CUANDO SE DESCONOCEN LAS VARIANZAS

POBLACIONALES, PERO SE SABE QUE SON IGUALES. $\sigma_1^2 = \sigma_2^2$

$$\frac{\sigma_1^2}{\sigma_2^2} = 1$$

CASO 3

$$\mu_1 = \mu_2$$

P.H. SOBRE LA IGUALDAD DE MEDIAS DE 2 POBLACIONES

$$\sigma_1^2 \neq \sigma_2^2$$

NORMALES CUANDO SE DESCONOCEN LAS VARIANZAS

POBLACIONALES, PERO SE SABE QUE SON DIFERENTES.

$$\frac{\sigma_1^2}{\sigma_2^2} \neq 1$$


T_0^+

CECAYA

CASO 1: PRUEBA SOBRE IGUALDAD DE DOS MEDIAS POBLACIONALES CON NORMALES CUANDO SE CONOCEN LAS VARIANZAS POBLACIONALES σ_1^2, σ_2^2

SI SE DESEA PROBAR QUE DOS MEDIAS DE LAS POBLACIONES (CON DISTRIBUCIONES NORMALES) SON IGUALES, ENTonces EL ESTADÍSTICO DE PRUEBA ES:

$$Z_0 = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$



LA PRUEBA CON ALTERNATIVA DE DOS LADOS ES:

$$\begin{aligned} H_0: \mu_1 &= \mu_2 \\ H_1: \mu_1 &\neq \mu_2 \end{aligned}$$

CUANDO LAS VARIANZAS POBLACIONALES SE DESCONOCEN, SE PUEDE UTILIZAR LAS VARIANZAS MUESTRALES PARA LAS POBLACIONES, SIGUIENDO QUE LAS MUESTRAS SEAN GRANDES.

SI SE DESEA PROBAR LA DIFERENCIA DE MEDIAS, ENTONES EL ESTADÍSTICO SE NORMALIZA RESTANDOLE LA DIFERENCIA DE MEDIAS.

(AQUÍ TE PROpones $Z_0 = \frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$)

$$Z_0 = \frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

CASO 2 PH. SOBRE IGUALDAD DE MEDIAS DE 2 POBLACIONES NORMALES

CUANDO SE DESCONOCEN LAS VARIANZAS POBLACIONALES σ_1^2, σ_2^2 PERO SE SABE QUE SON IGUALES. $\sigma_1^2 = \sigma_2^2$

MUESTRAS PEQUEÑAS DE POBLACIONES NORMALES Y VARIANZAS DESCONOCIDAS PERO IGUALES.

EL ESTADÍSTICO DE PRUEBA ES:

$$T_0 = \frac{\bar{X}_1 - \bar{X}_2}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

DONDE

$$S_p^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1 + n_2 - 2}$$

$$T_0 \sim t_{(n_1+n_2-2)}$$

CASO 3 PH. SOBRE IGUALDAD DE MEDIAS DE 2 POBLACIONES NORMALES

CUANDO SE DESCONOCEN LAS VARIANZAS POBLACIONALES σ_1^2, σ_2^2 PERO SE SABE QUE SON DIFERENTES $\sigma_1^2 \neq \sigma_2^2$

MUESTRAS PEQUEÑAS DE POBLACIONES NORMALES Y VARIANZAS DESCONOCIDAS PERO DIFERENTES.

CUANDO LAS VARIANZAS SON DIFERENTES, ENTonces NO EXISTE UN ESTADÍSTICO T EXACTO PARA HACERLA LA PRUEBA SOBRE LA IGUALDAD DE MEDIAS! SIN EMBARGO, UNA BUENA APROXIMACIÓN LA PROPORCIONA EL ESTADÍSTICO.

$$T_0^+ = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$$

EL CUAL TIENE DISTRIBUCIÓN APROXIMADAMENTE t , i.e., $T_0^+ \sim t(v)$:
DONDE EL NUMERADOR DE GRADOS DE LIBERTAD ESTÁ DADO POR:

$$V \approx \frac{\left[\left(\frac{S_1^2}{n_1} \right) + \left(\frac{S_2^2}{n_2} \right) \right]^2}{\frac{\left(\frac{S_1^2}{n_1} \right)^2}{n_1+1} + \frac{\left(\frac{S_2^2}{n_2} \right)^2}{n_2+1}}$$

Y DEBE UTILIZARSE EL ENTERO MÁS CERCANO.

CECMVA

EJERCICIO IGUALDAD DE MEDIAS.

MEDIDAS RESPECTO AL ESFUERZO CORTANTE OBTENIDAS A PARTIR DE PRUEBAS DE COMPRRESIÓN INDEPENDIENTES PARA DOS TIPOS DE SUELOS DIERON LOS RESULTADOS SIGUIENTES (MEDIDAS EN TONELAJE POR METRO CUADRADO).

SUELTO TIPO I

$$\begin{aligned}n_1 &= 36 \\V_1 &= 1.65 \\S_1 &= 0.26\end{aligned}$$

SUELTO TIPO II

$$\begin{aligned}n_2 &= 35 \\V_2 &= 1.43 \\S_2 &= 0.22\end{aligned}$$

¿DIFERENCIAN LOS DOS SUELOS CON RESPECTO AL ESFUERZO CORTANTE PROMEDIO, A NIVEL DE SIGNIFICACIÓN DE 1%?

PRIMERO PLANTEAR HIPÓTESIS

$$H_0: \mu_1 - \mu_2 = 0 \quad X$$

$$H_1: \mu_1 - \mu_2 \neq 0 \quad \checkmark$$

SEGUNDO LOCAL ESTADÍSTICO DEBEMOS USAR?

$$z_0 = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$


EL ESTADÍSTICO DE PRUEBA ES

$$z_0 = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

VALUANDO

$$z_0 = \frac{1.65 - 1.43}{\sqrt{\frac{(0.26)^2}{36} + \frac{(0.22)^2}{35}}} = 3.65$$

$$\text{CON } \alpha = 0.01 \quad P(Z > z) = \alpha/2 \quad P(Z > z) = 0.005 \quad z = 2.575$$



Norma

PRUEBAS DE HIPÓTESIS PARA LA VARIANZA

ANALISIS

ESTADISTICO

SI SE DESEA PROBAR LA VARIANZA DE UNA POBLACION CON DISTRIBUCION NORMAL, ENTONCES EL ESTADISTICO DE PROBAR ES:

$$X_0^2 = \frac{(n-1)S^2}{G^2}$$


DONDE S^2 ES LA VARIANZA MUESTRAL Y $X^2 \sim \chi^2_{(n-1)}$

LA PRUEBA DE HIPÓTESIS DE DOS CAJAS ES:

$$H_0: G^2 = G_0^2$$

$$H_1: G^2 \neq G_0^2$$

Y LA HIPÓTESIS NULA SE RECHAZA SI $X_0^2 > \chi^2_{\alpha/2, n-1}$
O BIEN $X_0^2 < X_1 - \chi^2_{\alpha/2, n-1}$



$$\chi^2_{0.05} = \frac{2\ln(\alpha)}{\theta^2} = \frac{2\ln(1-\alpha)}{\theta^2}$$

$$8.8282 \rightarrow \text{rechazar}$$

$$2.70 \rightarrow \text{aceptar}$$

Norma

CECMAT

EJERCICIO:

LA DISPERSIÓN O VARIANZA, DE TIEMPO DE ACARREO EN UN PROYECTO DE CONSTRUCCIÓN SON DE GRAN IMPORTANCIA PARA EL SOBRESTANTE, YA QUE LOS TIEMPOS MUY VARIABLES DE ACARREO ORIGINAN PROBLEMAS EN LA PROGRAMACIÓN DE LOS TRABAJOS. EL ENCARGADO DE COSTOS ASEGURA QUE EL INTERVALO DE TIEMPO DE ACARREO NO DEBE SER MAYOR QUE 40 MINUTOS (ESTE INTERVALO ES LA DIFERENCIA ENTRE EL TIEMPO MAYOR Y EL MENOR). SI SE SUPONE QUE ESTOS TIEMPOS DE ACARREO ESTAN DISTRIBUIDOS EN FORMA APROXIMADAMENTE NORMAL, EL SOBRESTANTE CREE QUE LA AFIRMACIÓN ACERCA DE LOS LÍMITES QUIERE DECIR QUE LA DESVIACIÓN ESTÁNDAR σ DEBE SER APROXIMADAMENTE 10 MINUTOS. SE MIDIERON EN REALIDAD 15 TIEMPOS DE ACARREO Y SE CALCULÓ UN PROMEDIO DE 142 MINUTOS Y UNA DESVIACIÓN ESTÁNDAR DE 12 MINUTOS. ¿PODRÁ RECHAZARSE LA AFIRMACIÓN DE $\sigma = 10$ EN EL NIVEL DE SIGNIFICANCIA DEL 5%?

PRIMERO: PLANTEAR LA HIPÓTESIS.

$$H_0: \sigma \leq 10$$

$$H_1: \sigma > 10$$

$$H_0: \sigma^2 \leq 100$$

$$H_1: \sigma^2 > 100$$

SEGUNDO: CUÁNDO ES EL ESTADÍSTICO QUE DEBEMOS USAR?

$$\chi^2_0 = \frac{(n-1)S^2}{\sigma^2} = \frac{(14)(12)^2}{100} = 20.16$$


LA REGIÓN DE RECHAZO ES $\chi^2 > \chi^2_{0.05, 14}$

$$\chi^2_{0.05, 14} = 23.6898$$

POUESTO QUE

$$\chi^2_0 < \chi^2_{0.05} \quad 20.16 < 23.69$$

NO SE RECHAZA. CON BASE EN LA INFORMACIÓN DE LA MUESTRA NO HAY SUFFICIENTE EVIDENCIA PARA CONCLUIR QUE LA DESVIACIÓN ESTÁNDAR ES SUPERIOR A 10 MINUTOS, CON $\alpha = 0.05$



PRUEBAS DE HIPÓTESIS PARA LA IGUALDAD DE VARIANZAS.

PARA PROBAR LA IGUALDAD DE DOS VARIANZAS DE POBLACIONES NORMALES CON PARÁMETROS μ_1, σ_1^2 , μ_2 Y σ_2^2 Y SE UTILIZA EL ESTADÍSTICO:

$$F_0 = \frac{s_1^2}{s_2^2}$$

DONDE $F \sim F_{n_1-1, n_2-1}$

Y LA PRUEBA DE DOS LADOS Quedaría como:


$$\begin{aligned} H_0: \sigma_1^2 &= \sigma_2^2 \\ H_1: \sigma_1^2 &\neq \sigma_2^2 \end{aligned}$$

LA HIPÓTESIS SERÍA RECHAZADA SI

$$F_0 > f_{\alpha/2, n_1-1, n_2-1}$$

O BIEN

$$F_0 < f_{1-\alpha/2, n_1-1, n_2-1}$$



PRUEBAS DE HIPÓTESIS SOBRE UNA PROPORCIÓN

ES UN CASO PARTICULAR DE LA MEDIA POR LO QUE NO DEBE SORPRENDER QUE EL ESTADÍSTICO DE PRUEBA SEA MUY SIMILAR

$$z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$$

Y LA HIPÓTESIS PODRÍA PLANTEAR COMO:

$$H_0: p = p_0$$

$$H_1: p \neq p_0$$

PARA UNA PRUEBA DE DOS LADOS